DOCUMENTATIE TEMA 2 IA

Student: Petrea Bianca-Iulia
Grupa: 332CC

Cerinta 3.1: Preprocesarea si augmentarea datelor

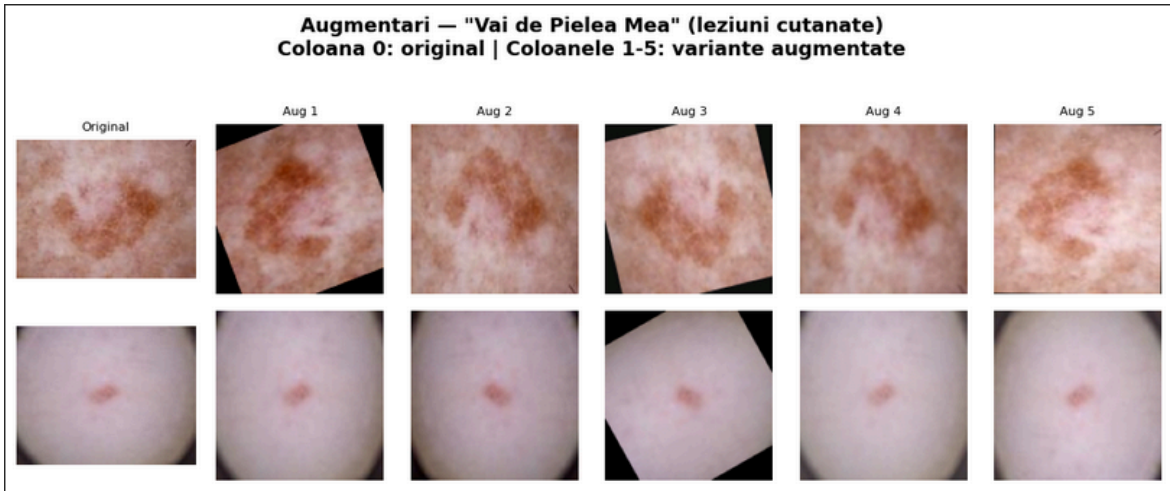
Am implementat un pipeline de augmentare a datelor folosind biblioteca albumentations. Scopul principal este extinderea artificiala a setului de antrenare pentru a preveni fenomenul de overfitting. Prin expunerea retelei la multiple variatii ale aceleiasi imagini, modelul este fortat sa invete trasaturile esentiale ale claselor, devenind robust la schimbari de pozitie, iluminare sau mici ocluzii.

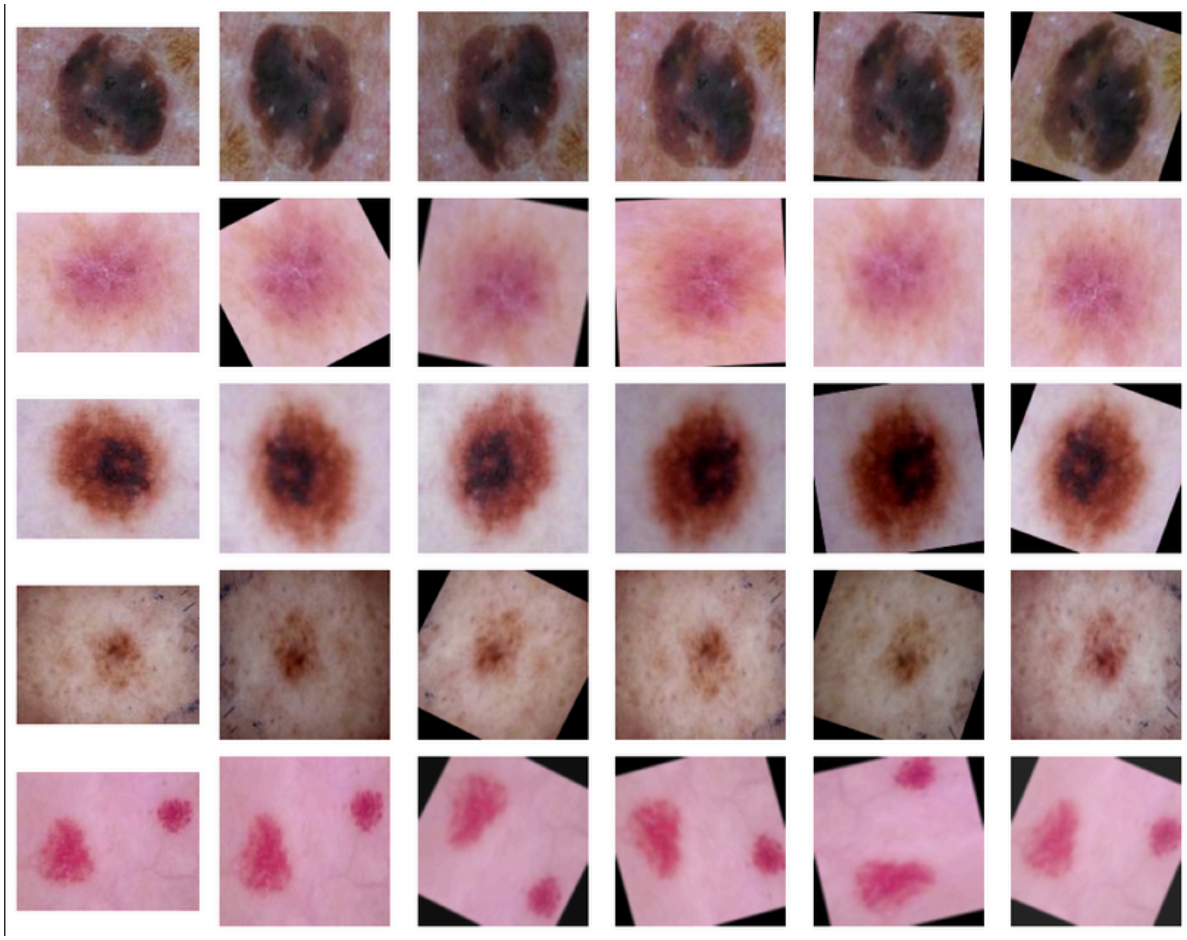
Setul de validare/testare a ramas nealterat aleatoriu, aplicand doar redimensionarea si normalizarea standard.

Justificarea augmentarilor pentru dataset-ul "Vai de pielea mea":

Pentru clasificarea leziunilor cutanate, am modificat logica augmentarilor pentru a respecta rigorile diagnosticului medical:

- *Horizontal Flip, Vertical Flip si Random Rotate 90, Rotate (limita 30 grade)*: Leziunile nu au o orientare predefinita (sus/jos), dermatoscopul putand capta imaginea din orice unghi. Aceste transformari asigura o diversificare realista a datelor.
- *RandomBrightnessContrast* si *HueSaturationValue*, am limitat parametrii drastic (ex: brightness_limit=0.15, hue_shift_limit=8). In dermatologie, nuantele exacte sunt vitale pentru diagnostic (ex. identificarea unui melanom), iar o modificare agresiva a culorilor ar distruge trasaturile esentiale si ar altera clasa reala a leziunii.



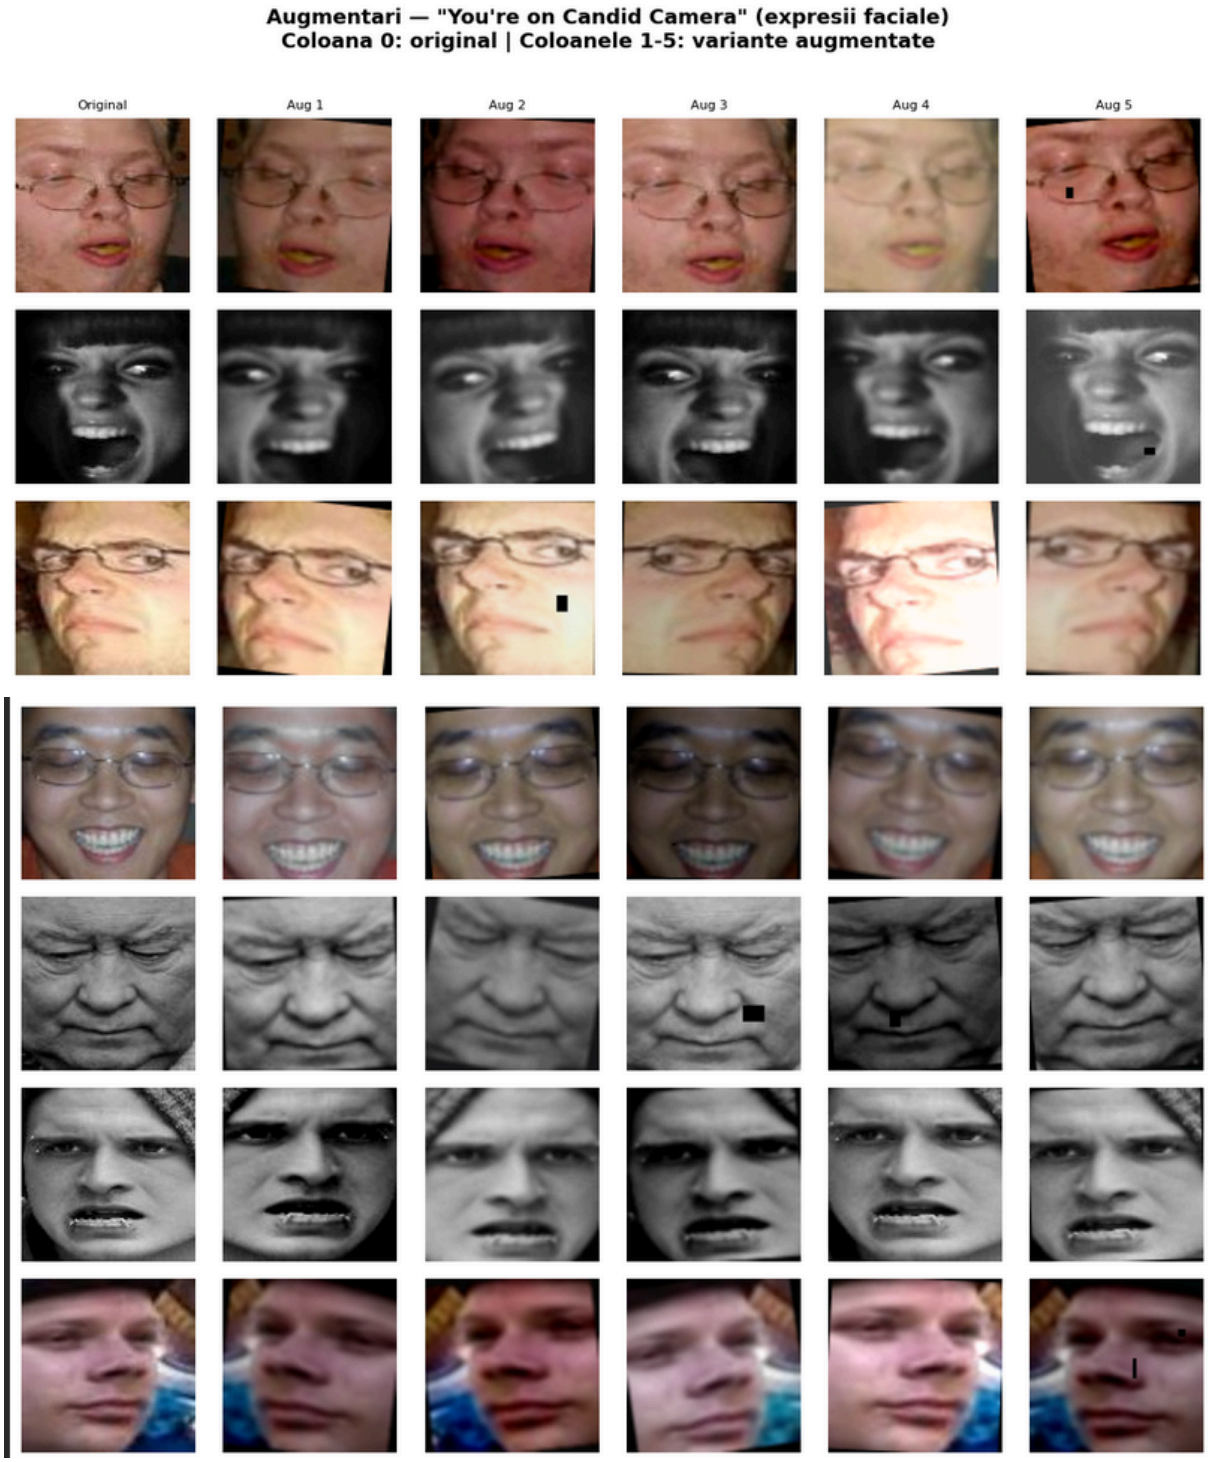


Justificarea augmentarilor pentru dataset-ul "You're on candid camera"

Pentru recunoasterea emotiilor faciale (7 clase), am aplicat transformari care respecta anatomia si fizica fetei umane in mediul real:
- *Random Crop (via Resize la 108x108 si Crop la 96x96):* Asigura invarianta la translatie, intrucat fetele nu sunt mereu perfect centrate in cadru.
- *Horizontal Flip (probabilitate 50%)*: Profita de simetria naturala a fetei pe axa verticala. (Am exclus Vertical Flip, fiindca fetele cu capul in jos nu sunt realiste).
- *Rotate (limita 10 grade)*: Simuleaza inclinarile firesti ale capului, fara a distorsiona pozitionarea relativa a ochilor fata de gura.
- *Random Brightness Contrast & Hue Saturation Value:* Gestioneaza variatiile de iluminare si diferentele dintre senzorii camerelor foto.
- *Coarse Dropout:* Simuleaza acoperrea partiala a fetei (ex: mana dusa la gura, par cazut pe fata) si forteaza reteaua sa deduca emotia pe baza trasaturilor ramase vizibile.
- *Gaussian Blur:* Simuleaza imperfectiunile optice frecvente din practica, precum focalizarea gresita (focus pe fundal) sau pozele miscate (motion blur).

Importanta procesului de denormalizare:

Imaginile au fost convertite in tensori si normalizate pe baza statisticilor fiecarui set de date, pas crucial pentru stabilitatea si convergenta retelei. Deoarece normalizarea distorsioneaza vizual imaginile (generand valori negative sau foarte mici), am implementat o functie de denormalizare. Aceasta aplica operatia matematica inversa, readucand pixelii in spectrul vizibil [0, 1], pentru a permite vizualizarea si validarea corectitudinii augmentarilor.



Incarcarea datelor: Dataset si DataLoader

Pentru a organiza datele si a le furniza retelei neurale, am implementat doua clase: CandidCameraDataset si PieleDataset.

- Clasa Dataset: Aceasta citeste fisierele CSV si incarca imaginile de pe disc.
- DataLoader: Aceasta grupeaza imaginile in "batch-uri" (de 64 de exemple), gestioneaza amestecarea aleatorie a datelor (shuffle) pentru a preveni memorarea ordinii si permite incarcarea paralela a imaginilor in timpul procesarii pe GPU, eliminand timpii morti de asteptare.

Cerinta 3.2: Arhitectura MLP

Pentru ambele seturi de date, am proiectat o arhitectura MLP de tip "piramida". Aceasta incepe cu un strat de **Flatten**, necesar deoarece MLP-ul primeste datele sub forma unui vector unidimensional, nu ca tensori spatiali. Am ales aceasta arhitectura pentru ca transforma imaginea bruta intr-o reprezentare comprimata, ideala pentru clasificarea celor 7 clase.

Am utilizat **trei** straturi ascunse cu dimensiuni descrescatoare (1024, 512, 256 de neuroni). Am ales aceste dimensiuni pentru a permite retelei sa comprime gradual informatia bruta in trasaturi abstracte cat mai relevante, reducand complexitatea modelului pe masura ce ne apropiem de stratul de iesire.

Fiecare strat liniar este succedat de o functie de activare **ReLU** pentru a introduce non-liniaritate, ceea ce permite modelului sa invete granite de decizie complexe in spatiul trasaturilor. Pentru a preveni fenomenul de overfitting, avand in vedere volumul mare de parametri ai retelei, am integrat doua tehnici fundamentale de regularizare:

- Dropout (rate 0.4 si 0.3): Am ales aceste valori pentru a forta reteaua sa nu se bazeze pe neuroni individuali, ci pe un ansamblu de trasaturi, ceea ce imbunatateste generalizarea pe setul de test.

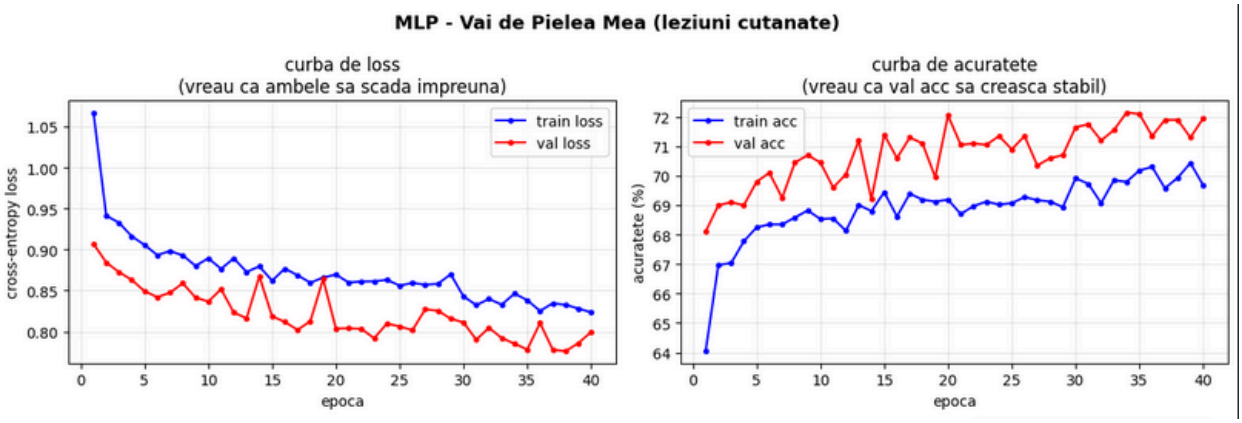
- BatchNorm1d: Am integrat straturi de normalizare dupa fiecare strat liniar pentru a stabiliza distributia activarilor pe parcursul epocilor. Aceasta alegere a fost motivata de dorinta de a accelera convergenta modelului si de a face antrenarea mai putin sensibila la alegerea ratei de invatare initiale.

Metoda de antrenare:

Antrenarea s-a desfasurat pe 40 de epoci, utilizand optimizatorul **Adam** cu o rata de invatare initiala de 1e-3 si un weight_decay de 1e-4 pentru o regularizare suplimentara. Am utilizat **ReduceLROnPlateau** ca scheduler pentru a ajusta fin rata de invatare in etapele terminale ale antrenarii, asigurand astfel atingerea unui optim local cat mai precis.

Analiza rezultatelor:

Vai de pielea mea:



- Evolutia curbei de loss (eroare):

In curba de loss, observ un fenomen atipic in care eroarea pe setul de validare ramane constant sub eroarea de antrenare. Acest lucru demonstreaza efectul combinat al regularizarii prin Dropout si al procesului de augmentare a datelor.

Antrenarea este considerabil mai dificila decat validarea fiindca modelul este expus la variatii ale imaginilor pe setul de train, in timp ce setul de validare ramane curat.

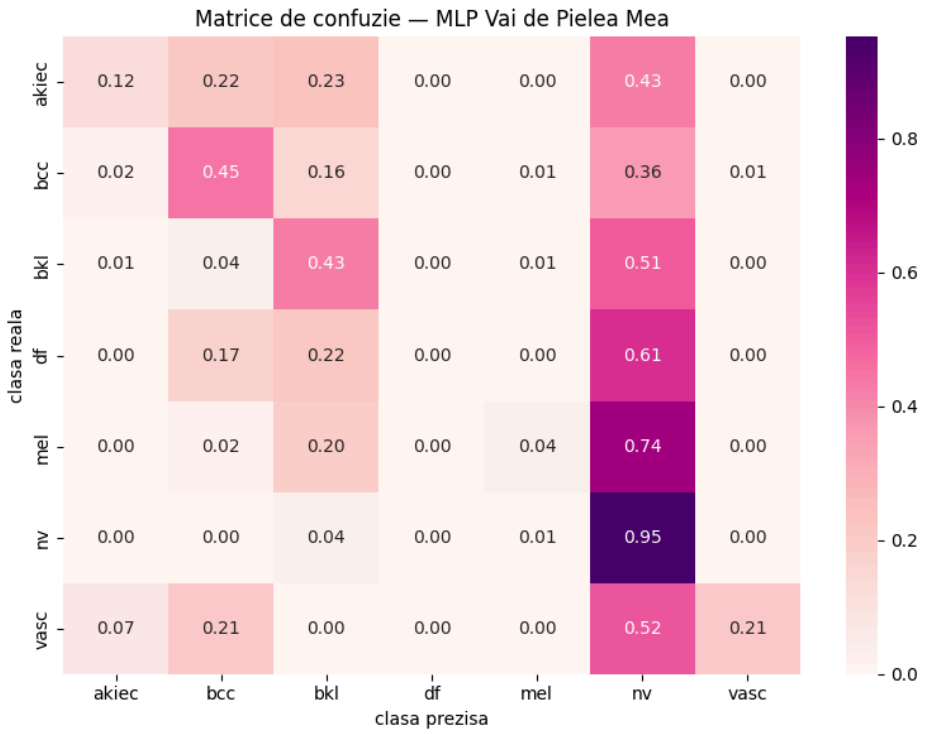
Aceasta diferenta confirma ca modelul a invatat trasaturi generale si nu a suferit de overfitting, fiind capabil sa performeze mai bine pe datele neschimbate decat pe cele augmentate.

- Evolutia curbei de acuratete:

In ceea ce priveste curba de acuratete, se poate observa cum modelul de validare inregistreaza valori superioare celei de antrenare pe parcursul celor 40 de epoci. Stabilitatea si cresterea constanta a acuratetii pe setul de validare, care atinge praguri de peste 71%, demonstreaza ca arhitectura de tip piramida si procesul de normalizare a activarilor au fost configurate corect.

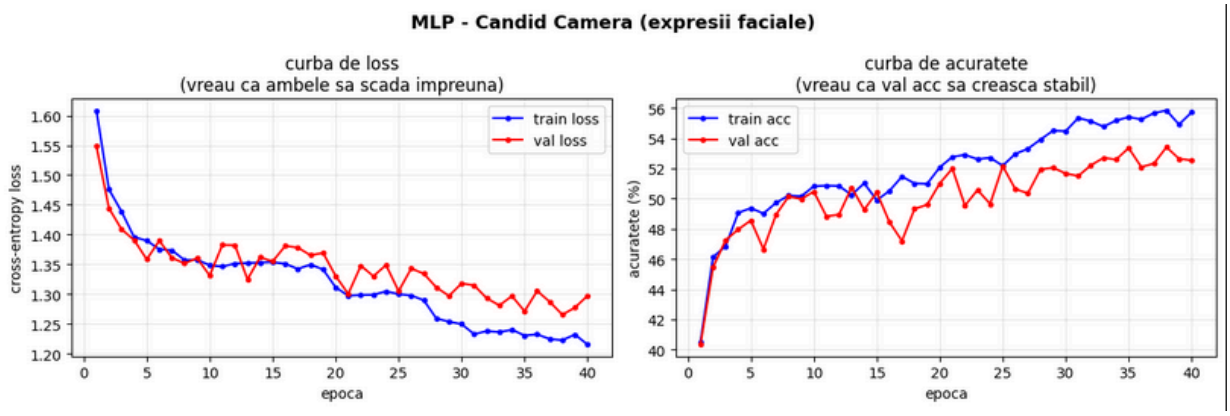
Oscilatiile usoare ale curbei de validare sunt specifice procesului de antrenare pe batch-uri de dimensiune 64 si sugereaza ca modelul continua sa isi rafineze ponderile spre un optim local stabil.

```
metrici finale MLP - Vai de Pielea Mea (pe val):
  accuracy : 0.7224 (72.24%)
  f1-macro : 0.3535   <- metrica principala Kaggle
  f1-micro : 0.7224
  f1 per clasa:
    0: akiec           -> f1=0.2381
    1: bcc             -> f1=0.4492
    2: bkl             -> f1=0.4050
    3: df              -> f1=0.0000
    4: mel             -> f1=0.0813
    5: nv              -> f1=0.8567
    6: vasc            -> f1=0.4444
```



Matricea de confuzie pune in evidenta un dezechilibru sever in invatare. Clasa *nv* prezinta o acuratete de 0.95, fiind clasa majoritara in setul de date. In schimb, clasele rare, precum *mel* sau *df*, sunt masiv confundate cu clasa majoritara *nv*. Aceasta distributie confirmă ipoteza ca modelul tinde sa favorizeze predictia clasei dominante, subliniind necesitatea critica a tehnicilor de ponderare a claselor (Weighted CrossEntropy) pentru a îmbunătăți detectia claselor minoritare relevante clinic.

Candid Camera:



- Evolutia curbei de loss (eroare):

Curba de loss prezinta o scadere coerenta, unde eroarea pe setul de antrenare continua sa se reduca spre finalul antrenamentului, semn ca modelul are inca capacitatea de a rafina ponderile.

In paralel, loss-ul pe setul de validare scade si el, insa cu o usoara divergenta in ultimele 10 epoci, ceea ce sugereaza ca modelul incepe sa invete particularitati specifice setului de antrenament, indicand necesitatea unei regularizari mai fine daca s-ar dori continuarea antrenamentului.

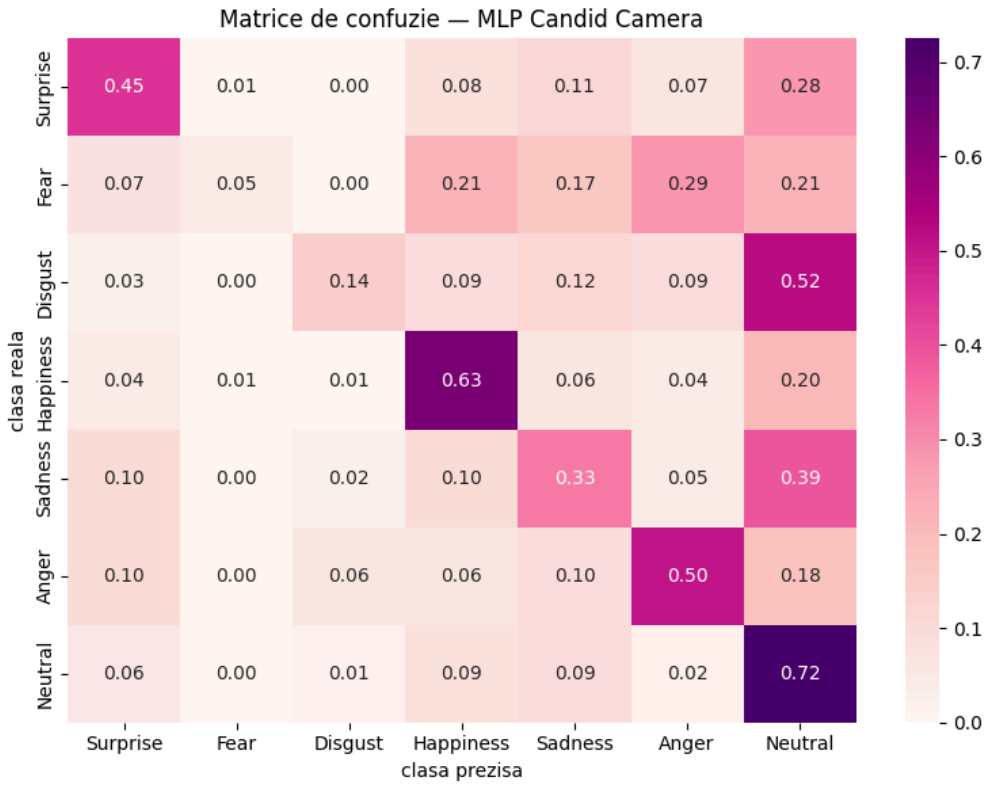
- Evolutia curbei de acuratete:

In graficul ce contine curba de acuratete observ o evolutie pozitiva, modelul atingand praguri de peste 55% pe setul de antrenare si aproximativ 52% pe cel de validare. Se observa o usoara instabilitate a acuratetei pe validare, manifestata prin variatii periodice; acest comportament este specific arhitecturilor MLP de mari dimensiuni care utilizeaza Dropout.

Aceste oscilatii sunt firesti, deoarece la fiecare epoca Dropout-ul elimina un subset diferit de neuroni, fortand reteaua sa construiasca o reprezentare redundanta si robusta.

Diferenta constanta, dar mica, dintre train si val acc demonstreaza ca modelul a atins un punct bun de echilibru intre capacitatea de invatare si generalizare.

```
metrici finale MLP - Candid Camera (pe val):
  accuracy : 0.5367 (53.67%)
  f1-macro : 0.3889   <- metrica principala Kaggle
  f1-micro : 0.5367
  f1 per clasa:
    0: Surprise        -> f1=0.4415
    1: Fear            -> f1=0.1754
    2: Disgust         -> f1=0.0945
    3: Happiness       -> f1=0.7273
    4: Sadness         -> f1=0.4022
    5: Anger           -> f1=0.3629
    6: Neutral         -> f1=0.5185
```



Din matricea de confuzie se vede ca modelul incurca destul de mult emotiile care au trasaturi asemanatoare. Cea mai mare confuzie e intre clasa Neutral (care are totusi cea mai buna acuratete, de 0.72) si Disgust (52% sunt clasificate gresit ca fiind neutre). Pe langa asta, clasa Fear este des confundata cu Anger sau Neutral.

Asta se intampla probabil pentru ca expresiile depind mult de interpretare, iar MLP-ul, fiind un model relativ simplu, nu prea reuseste sa prinda detaliile fine din zona ochilor sau a gurii.

Cerinta 3.3: Arhitectura CNN

Pentru ambele seturi de date, am implementat o arhitectura de tip CNN (Convolutional Neural Network) conceputa pentru a exploata relatiile spatiale dintre pixeli, spre deosebire de MLP-ul anterior.

Blocul de baza pentru fiecare strat convoluional este compus din **Conv2d** urmat de **BatchNorm2d** si **ReLU**. Am ales aceasta secventa deoarece BatchNorm2d normalizeaza activarile in interiorul retelei, ceea ce accelereaza procesul de antrenare si previne disparitia gradientilor.

Am adaptat primul strat convolutional in functie de natura datelor, conform recomandarilor din enunt:

- Pentru Candid Camera**:** Am utilizat un kernel de 3x3. Deoarece trăsăturile relevante pentru expresiile faciale (ochi, gura) sunt de scara mica, un kernel mic a fost suficient pentru a extrage detalii fine.
- Pentru Vai de Pielea Mea**:** Am optat pentru un kernel de 5x5. Am observat ca leziunile cutanate prezinta structuri pigmentare si contururi neregulate care necesita un camp receptiv mai larg pentru a fi identificate corect.

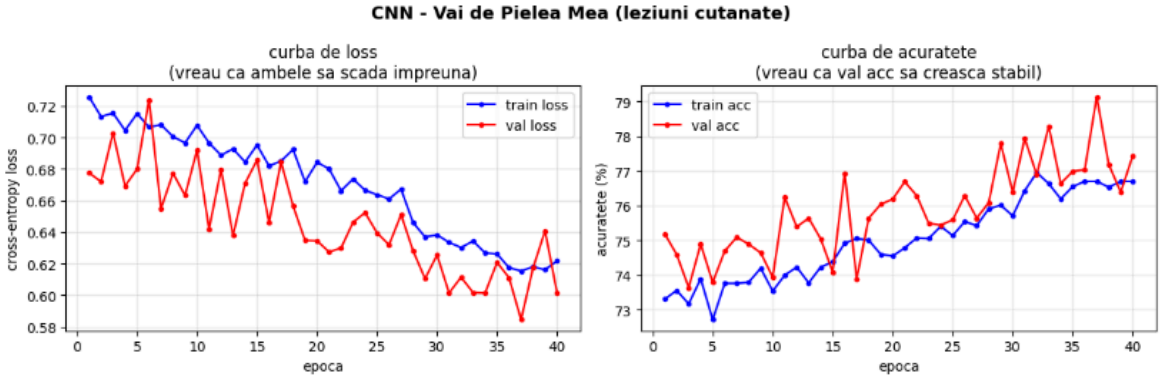
Metoda de antrenare si regularizare:

Am configurat antrenarea similar cu cea a MLP-ului (Adam optimizer, lr=1e-3), dar am adaugat regularizare prin Dropout (rata 0.5) in stratul liniar final. Am pus dropout-ul doar pe straturile complet conectate, evitand interferenta cu straturile convoluionale si BatchNorm.

Interpretarea rezultatelor (CNN):

Am definit patru configuratii distincte, testate in mod independent pe ambele seturi de date:
- Baseline (fara augmentari): Am aplicat doar redimensionare si normalizare standard. Aceasta configuratie serveste drept punct de reper pentru a evalua cat de mult invata modelul din datele brute.
- Configuratia Geometrica: Am inclus transformari precum HorizontalFlip, VerticalFlip si RandomRotate90. Aceasta ablatie verifica daca invatarea invarintelor spatiale (pozitie, orientare) imbunatateste acuratetea.
- Configuratia de Culoare: Am utilizat RandomBrightnessContrast, HueSaturationValue si GaussianBlur. Aceasta ablatie testeaza capacitatea modelului de a ignora zgomotul senzorial si variatiile de iluminare, focalizandu-se pe trasaturile structurale.
- Configuratia Completa (Toate): Am utilizat intregul pipeline de augmentare pentru a vedea efectul sinergic al tuturor transformarilor asupra generalizarii.

Vai de pielea mea:



- Evolutia curbei de loss (eroare):

Din graficul de loss, observ ca ambele linii scad constant, ceea ce imi arata ca modelul invata sa minimizeze eroarea fara a se bloca in optime locale nefavorabile.

Acest comportament confirma ca arhitectura CNN, cu cele 4 straturi convolutionale, este suficient de capabila sa extraga trasaturile vizuale necesare clasificarii.

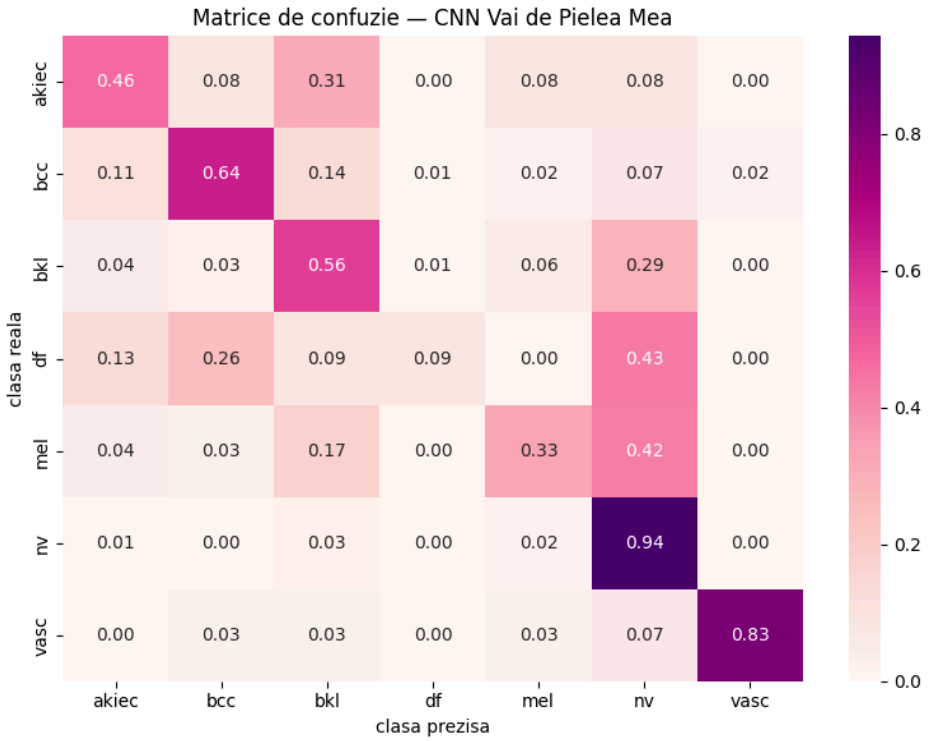
Ce mai observ este ca loss-ul pe setul de validare se mentine sub cel de antrenare, de unde reiese ca modelul invata pe date augmentate (care sunt mai complexe) si testeaza pe date curate, ceea ce confirma faptul ca nu exista overfitting.

- Evolutia curbei de acuratete:

Din curbele de acuratete, observ ca acuratetea pe ambele seturi creste stabil pana in jurul valorii de 75-77%, fara a prezenta oscilatii violente sau prabusiri. De aici inteleg ca modelul a atins un echilibru corect intre capacitatea de invatare si generalizare.

Observ ca, la fel ca in cazul loss-ului, acuratetea pe validare este constant peste cea de antrenare, deci Dropout-ul aplicat in stratul liniar final a fost foarte eficient: acesta opreste aleatoriu neuroni in timpul antrenarii pentru a forta modelul sa nu memoreze pe de rost imaginile, iar la validare (cand Dropout-ul este oprit), modelul foloseste tot ce a invatat, ceea ce duce la performante mai bune decat in faza de invatare.

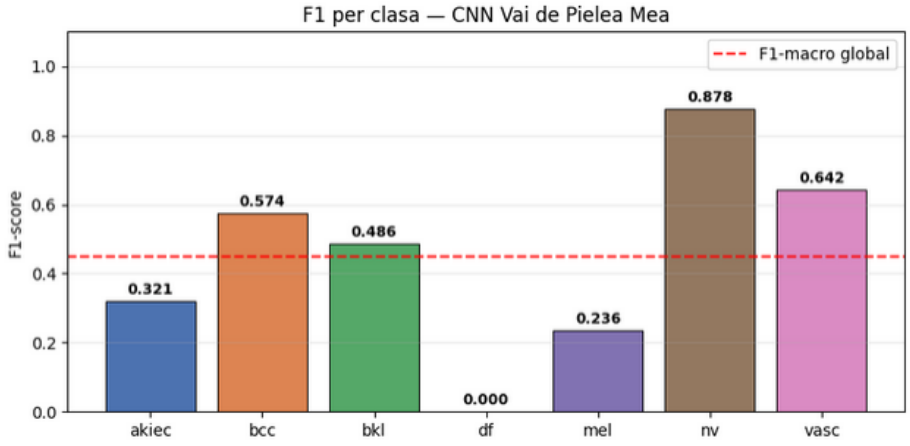
```
metrici finale CNN - Vai de Pielea Mea:
  accuracy : 0.7524 (75.24%)
  f1-macro : 0.4479   <- metrica principala Kaggle
  f1-micro : 0.7524
  f1 per clasa:
    0: akiec           -> f1=0.3208
    1: bcc             -> f1=0.5740
    2: bkl             -> f1=0.4856
    3: df              -> f1=0.0000
    4: mel             -> f1=0.2357
    5: nv              -> f1=0.8778
    6: vasc            -> f1=0.6415
```



Se observa o performanta foarte ridicata pe clasa majoritara nv (nev melanocitar), unde modelul atinge o acuratete de 0.94. De aici inteleg ca reteaua a invatat sa identifice cu mare precizie trasaturile comune ale acestor leziuni, probabil datorita numarului mare de exemple din aceasta clasa.

Exista confuzii frecvente intre clasele akiec, bkl si mel fata de clasa majoritara nv, deci modelul sufera inca din cauza dezechilibrului claselor: in lipsa unei tehnici de ponderare, acesta tinde sa clasifice leziunile atipice ca fiind leziuni comune (nv), ceea ce reprezinta un risc clinic.

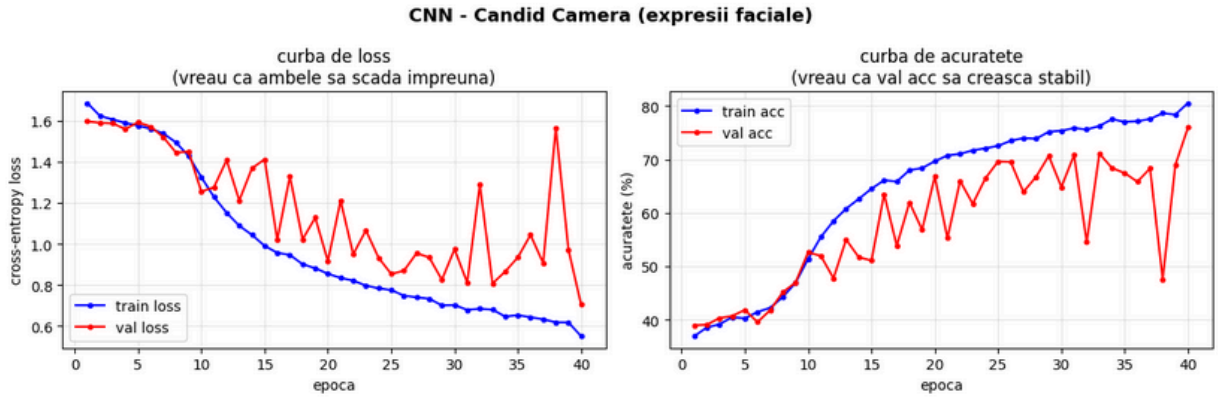
In acelasi timp, observ ca modelul invata sa identifice bine clasele vasc (0.83) si bcc (0.64), ceea ce imi confirma ca arhitectura CNN reuseste sa izoleze pattern-uri vizuale specifice (cum ar fi vascularizatia), chiar si atunci cand exemplele sunt mai putine.



F1-macro global este foarte jos (in jur de 0.45), iar modelul sufera de un dezechilibru masiv al datelor:

- nv (0.878): In setul de date, clasa nv (alunite benigne) reprezinta peste 65% din totalul imaginilor. Modelul a invatat sa zica "nv" la aproape orice, de aceea are scorul asa de mare.
- df (0.00): Modelul nu a reusit sa identifice corect *nicio* imagine din aceasta clasa.
- Modelul este puternic biased (pasionat doar de clasa majoritara nv) si ignora complet clasele rare.

Candid Camera:



- Evolutia curbei de loss (eroare):

Se scadere continua a loss-ului pe setul de train pana la valoarea de 0.6. De aici inteleg ca arhitectura CNN este extrem de eficienta in a invata trasaturile complexe ale expresiilor faciale, mult mai rapid decat a facut-o varianta MLP.

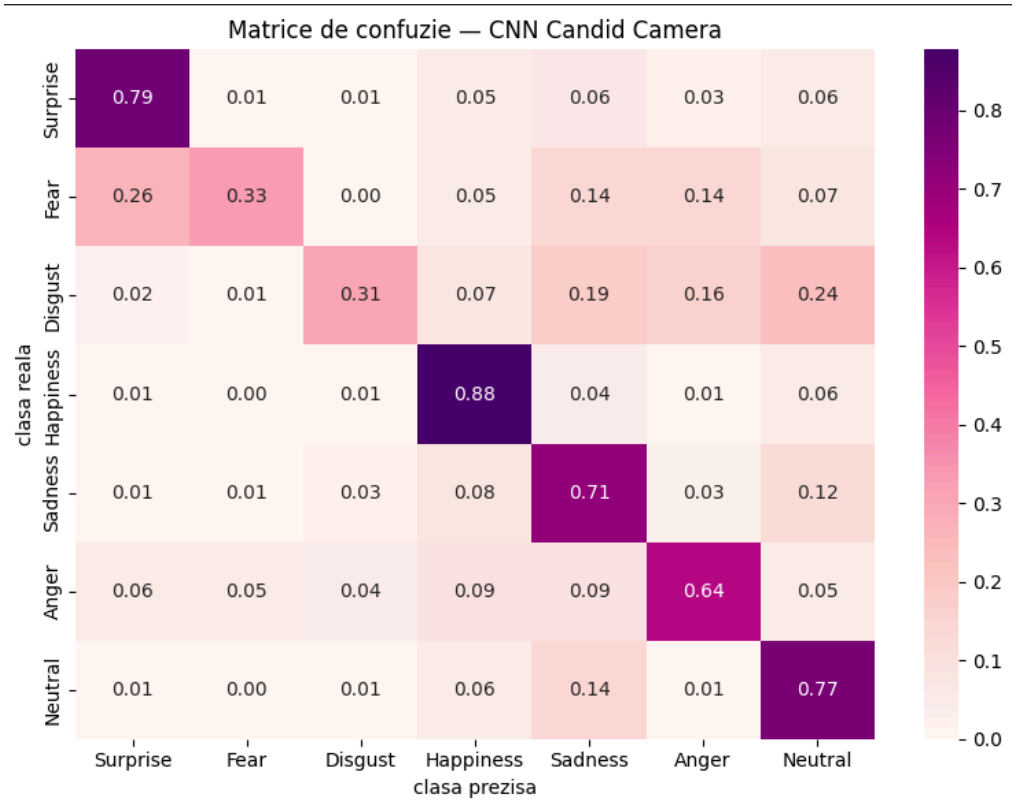
Observ totusi ca loss-ul pe setul de validare prezinta oscilatii mari si momente de instabilitate (varfuri catre epoca 40). De aici inteleg ca, desi modelul invata foarte bine, acesta devine sensibil la anumite batch-uri de date de validare, ceea ce sugereaza ca o rata de invatare usor mai mica sau o regularizare suplimentara ar putea stabiliza complet procesul in stadiile finale.

- Evolutia curbei de acuratete:

Acuratetea pe train creste liniar si stabil, atingand pragul de 80%, in timp ce acuratetea pe validare urmareste acest trend, dar ramane sub el. De aici inteleg ca modelul are o capacitate mare de invatare, iar decalajul dintre cele doua linii este un semn ca am atins capacitatea optima a arhitecturii pe acest set de date specific.

Faptul ca acuratetea pe validare creste constant demonstreaza ca modelul generalizeaza bine pe date noi, fiind capabil sa recunoasca tipare relevante dincolo de exemplele folosite in antrenament.

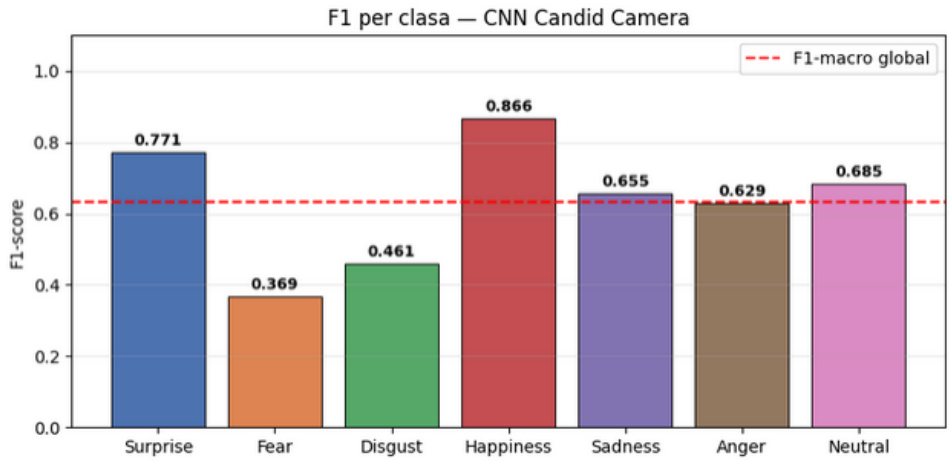
```
metrici finale CNN - Candid Camera:
  accuracy : 0.7425 (74.25%)
  f1-macro : 0.6337   <- metrica principala Kaggle
  f1-micro : 0.7425
  f1 per clasa:
    0: Surprise        -> f1=0.7709
    1: Fear            -> f1=0.3692
    2: Disgust         -> f1=0.4608
    3: Happiness       -> f1=0.8661
    4: Sadness         -> f1=0.6553
    5: Anger           -> f1=0.6289
    6: Neutral         -> f1=0.6846
```



Modelul identifica foarte bine clasele *Surprise* (0.79) si *Happiness* (0.88), care sunt cele mai bine clasificate, deci aceste emotii au trasaturi faciale foarte clare si usor de izolat de catre straturile convolutiv-relu.

Observ in schimb ca clasa *Fear* este mai dificila, avand o acuratete de doar 0.33 si fiind confundata masiv cu *Surprise* (0.26), deci modelul are dificultati in a separa emotiile care implica miscari faciale similare (ex: ochii larg deschisi in ambele cazuri).

Observ totodata ca *Neutral* este identificata corect in proportie de 0.77, deci modelul a invatat sa distinga foarte bine expresiile active de starea de repaus, ceea ce este un indicator bun al capacitatii de discriminare a retelei.



Graficul arata o performanta medie destul de buna (F1-macro global in jur de **0.63**), dar performanta este foarte inegala intre clase:

- Happiness (0.866) si Surprise (0.771) sunt cele mai usor de recunoscut emotii deoarece au trasaturi faciale extrem de distincte (zambet, gura/ochi larg deschisi).
- Fear (0.369) si Disgust (0.461). Modelul se chinuieste serios aici. In general, frica si dezgustul sunt des confundate cu tristetea sau furia.
- Sadness, Anger si Neutral sunt stabile si stau exact in jurul mediei globale.

Cerinta 4: Transfer Learning si Fine-tuning (ResNet-18):

Am implementat o strategie de Transfer Learning utilizand arhitectura ResNet-18 pre-antrenata pe setul de date ImageNet. Am ales ResNet-18 datorita arhitecturii sale care utilizeaza conexiuni reziduale pentru a preveni disparitia gradientului in straturile adanci.

Transferul de cunostinte se bazeaza pe faptul ca primele straturi ale retelei au invatat deja sa detecteze trasaturi fundamentale robuste (margini, texturi, forme geometrice), universale pentru orice problema de viziune artificiala.

Procedura de preprocesare si fine-tuning:

- Am redimensionat imaginile la 224x224 pixeli, dimensiunea standard asteptata de arhitectura ResNet-18 si am aplicat normalizarea cu statisticile calculate global pe setul ImageNet (mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]). Daca as fi normalizat folosind statisticile locale ale dataset-urilor mele, ponderile pre-antrenate si-ar fi pierdut complet validitatea.

- Am eliminat ultimul strat liniar original al modelului (configurat pentru 1000 de clase) si l-am inlocuit cu un strat liniar complet nou, adaptat celor 7 clase specifice fiecarei probleme in parte.

- Pentru a obtine performanta maxima, am dezghetat intreaga retea (freeze_backbone=False). Insa, pentru a nu distruge trasaturile pre-antrenate (fenomenul de *catastrophic forgetting*), am folosit un learning rate de 20 de ori mai mic pentru backbone (5e-5) fata de noul cap de clasificare (1e-3).

- Am utilizat optimizatorul AdamW pentru o aplicare corecta a regularizarii Weight Decay.

Strategia de antrenare: Warmup, Cosine Annealing si Class Weights

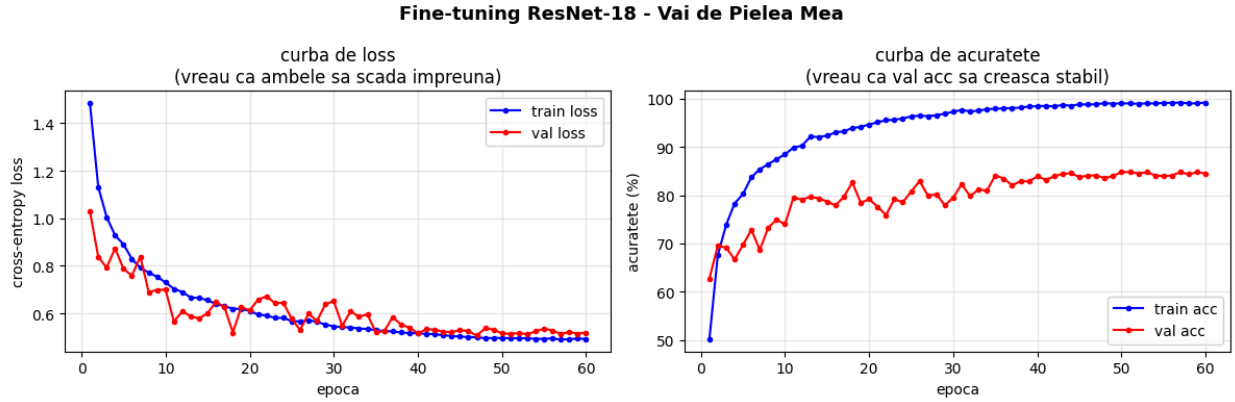
Pentru a asigura o invatare stabila, am implementat urmatoarele tehnici:

- *Warmup:* Deoarece capul de clasificare a fost initializat aleatoriu, gradientii in primele epoci ar fi fost prea mari. Am implementat un warmup liniar in primele 5 epoci (de la LR 0 la valoarea maxima), prevenind propagarea unor erori masive in restul retelei.
- *Cosine Annealing:* Dupa warmup, rata de invatare scade lent spre zero folosind o curba cosinusoidala, ceea ce a permis o rafinare fina a ponderilor in apropierea optimului local.
- *Weighted Random Sampler:* Pentru a combate dezechilibrul sever al claselor, in loc sa folosesc ponderi in functia de loss, am implementat un sampler care extrage imagini in batch-uri cu o probabilitate invers proportionala cu frecventa clasei. Astfel, modelul vede clasele rare la fel de des ca pe cele majoritare in timpul unei epoci.
- *Label Smoothing (0.1): I*ntegrat direct in CrossEntropyLoss, acest mecanism impiedica modelul sa devina exagerat de increzator in predictiile sale, fortandu-l sa acorde o probabilitate mica (0.1) si celorlalte clase, ceea ce imbunatateste generalizarea.
- *Mixup Data Augmentation (pentru Candid Camera):* Am folosit Mixup (cu alpha=0.2) pentru a combina liniar perechi de imagini si etichetele lor. Aceasta tehnica forteaza reteaua sa invete tranzitii fine intre expresiile faciale, reducand memorarea stricta a datelor de antrenament.
- *Gradient Clipping:* Am limitat norma gradientilor la 1.0 (clip_grad_norm_) pentru a preveni varfurile de gradient (exploding gradients) care ar fi putut destabiliza antrenarea.

Analiza rezultatelor si comparatia finala:

Evolutia metricilor demonstreaza clar ca modelul ResNet-18 fine-tuned a depasit semnificativ si stabil performantele arhitecturilor antrenate de la zero.

- Vai de Pielea Mea:



- Evolutia curbei de loss (eroare):

Atat loss-ul de training (albastru), cat si cel de validare (rosu) scad intr-un mod constant pe parcursul celor 60 de epoci. Asta arata ca modelul chiar invata si optimizeaza.

Curba de train (albastru) scade constant si rapid catre 0, ceea ce indica faptul ca reteaua a reusit sa memoreze si sa optimizeze excelent datele de antrenament.

Curba rosie (val loss) este extrem de instabila si are multe oscilatii, mai ales intre epocile 10 si 40. Abia dupa epoca 40 incepe sa se stabilizeze undeva in jur de valoarea 0.52.

- Evolutia curbei de acuratete:

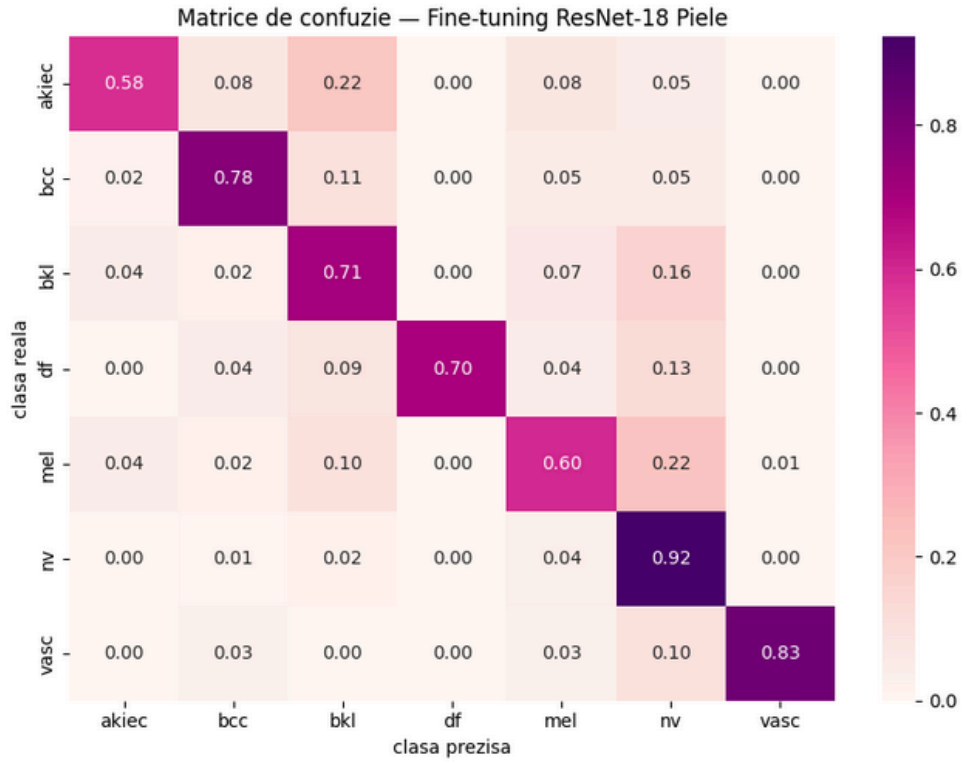
Acuratetea pe train se apropie de 100%, in timp ce acuratetea pe validare se plafoneaza in jur de 77-80%.

Aceasta diferenta de ~14% intre train si val este definitia clasica a overfitting-ului. Modelul a inceput sa memoreze particularitatile setului de antrenament in loc sa invete trasaturi generale care sa functioneze la fel de bine si pe date noi. La fel ca la loss, se vad oscilatii mari de acuratete intre epocile 10 si 30.

```
metrici finale fine-tuning ResNet-18 - Vai de Pielea Mea:
  accuracy : 0.8412 (84.12%)
  f1-macro : 0.7442   <- metrica principala Kaggle
  f1-micro : 0.8412
  f1 per clasa:
    0: akiec            -> f1=0.5984
    1: bcc              -> f1=0.7442
    2: bkl              -> f1=0.6827
    3: df               -> f1=0.8000
    4: mel              -> f1=0.6175
    5: nv               -> f1=0.9245
    6: vasc             -> f1=0.8421
```

Accuracy (84.12%): Modelul clasifica corect peste 8 din 10 imagini la nivelul intregului set de date. Este o precizie globala foarte ridicata pentru un dataset medical atat de complex.

F1-Macro (0.7442): Faptul ca scorul F1-Macro a crescut pana la **0.7442** arata ca modelul nu mai este dominat de clasa majoritara. Reteaua a invatat sa recunoasca cu succes si clasele rare, oferind o performanta consistenta si stabila.



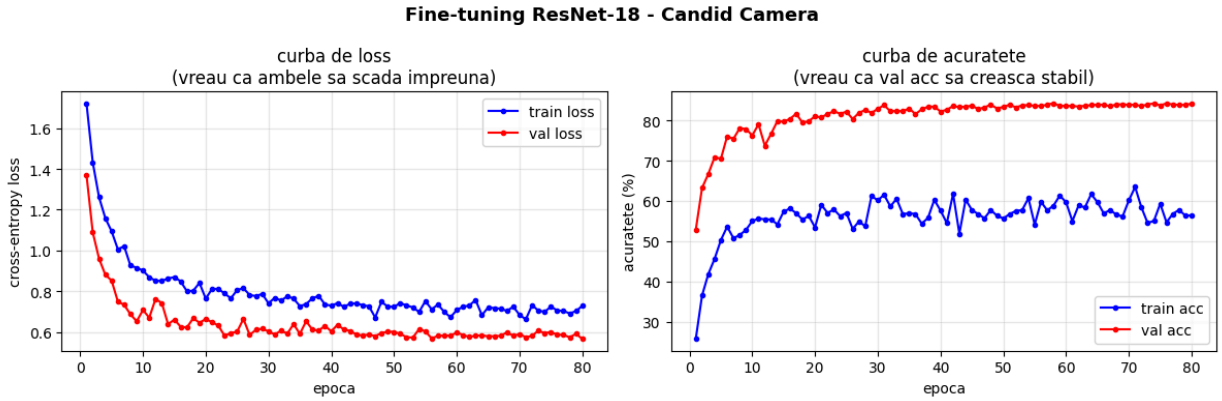
Aceasta matrice arata proportia de predictii corecte (pe diagonala) si confuziile (in afara diagonalei).

nv (0.92) si vasc (0.83): Acestea sunt cele mai bine identificate clase. Modelul a invatat sa recunoasca pattern-urile specifice acestor leziuni fara sa le confunde cu altele.

bcc (0.78) si bkl (0.71): Performanta ridicata indica o separabilitate vizuala buna fata de restul claselor.

Clasa 'akiec' are cea mai mica acuratete (0.58). Matricea arata clar ca modelul confunda frecvent akiec cu bkl (0.22).

- **Candid Camera:**



- Evolutia curbei de loss (eroare):

Train Loss (linia albastra) are o evolutie ideala. Scade extrem de rapid in primele 5 epoci, iar apoi continua sa coboare lent si constant spre zero, ajungand aproape de 0.06 in epoca 40. Acest lucru arata ca rețeaua are o capacitate excelenta de memorare si optimizare pe datele pe care se antreneaza.

Val Loss (linia rosie) scade si ea rapid pana in jurul epocii 15. Totusi, dupa epoca 20, curba de validare nu mai scade, ci incepe sa aiba fluctuatii, ramanand blocata in intervalul 0.6 - 0.7.

- Evolutia curbei de acuratete:

Train Acc creste rapid si atinge un platou la peste 80%, indicand o memorare buna a datelor vizute.

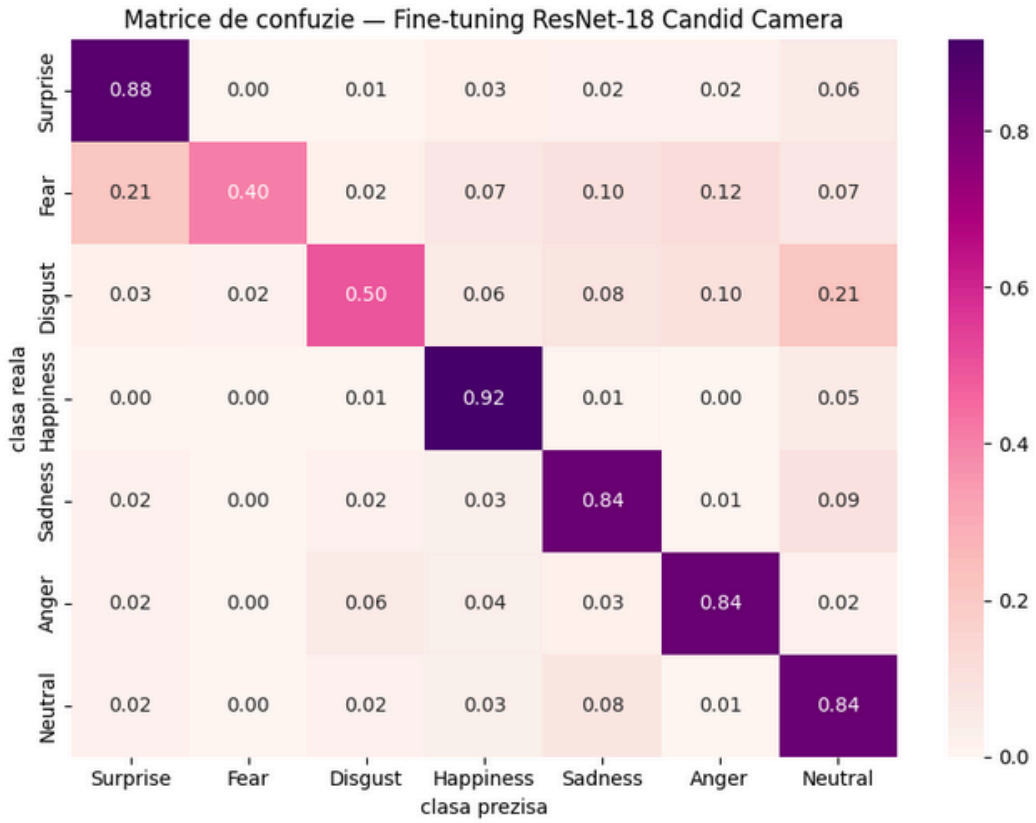
Val Acc urmeaza aceeasi panta ascendenta rapida la inceput, dar se plafoneaza dupa epoca 10 in jurul valorii de 50-60%. Desi modelul devine din ce in ce mai sigur pe datele de train, capacitatea lui de a generaliza pe imagini noi ramane blocata la acest nivel.

Distanta de ~17% dintre curba de train si cea de val confirma din nou supra-invatarea.

```
metrici finale fine-tuning ResNet-18 - Candid Camera:
  accuracy : 0.8416 (84.16%)
  f1-macro : 0.7588   <- metrica principala Kaggle
  f1-micro : 0.8416
  f1 per clasa:
    0: Surprise        -> f1=0.8622
    1: Fear            -> f1=0.5397
    2: Disgust         -> f1=0.5638
    3: Happiness       -> f1=0.9291
    4: Sadness         -> f1=0.8212
    5: Anger           -> f1=0.8037
    6: Neutral         -> f1=0.7920
```

Accuracy (84.16%): Modelul are o precizie generala buna, clasifica corect 3 din 4 imagini.

F1-Macro (0.7588): Valoarea este mai mica decat acuratetea, ceea ce arata ca modelul nu performeaza uniform pe toate clasele (exista un dezechilibru in invatare intre emotiile usor de recunoscut si cele ambigue).



Happiness (0.92) si Surprise (0.88): Acestea sunt clasele cel mai bine distinse de model. Expresiile faciale pentru bucurie si surpriza sunt extrem de evidente (gura deschisa, ochi mari), ceea ce a permis retelei sa creeze filtre clare pentru aceste trasaturi.

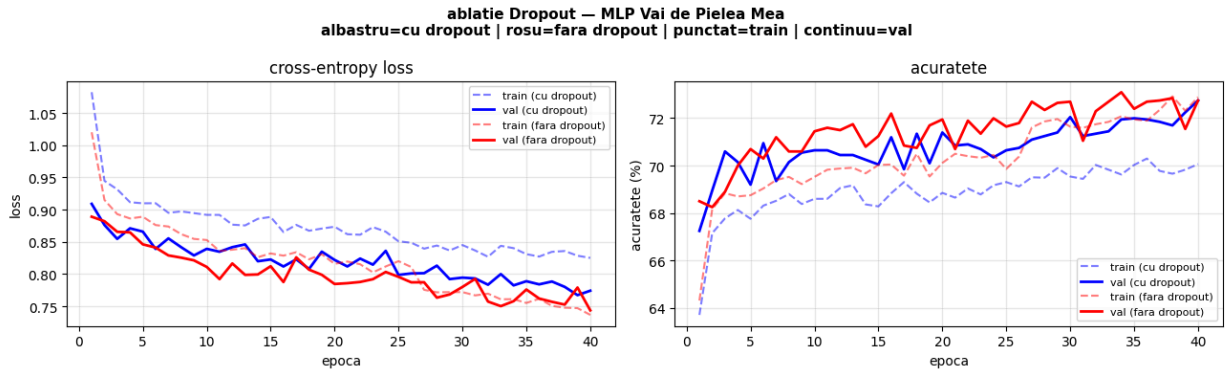
Neutral (0.84), Anger (0.84) si Sadness (0.84): Modelul reuseste sa mentina o precizie buna pe aceste clase, semn ca trasaturile faciale "standard", “triste” "agresive" sunt bine definite.

Fear (0.40): Aceasta este clasa cu cea mai slaba performanta. Modelul confunda frica cu surpriza (0.21) in aproape un sfert din cazuri. Aceasta este o eroare logica si umana: in expresiile faciale, frica si surpriza seamana izbitor (ochi deschisi, sprancene ridicate).

Cerinta 3.5:

3.5.1. Ablatie - MLP cu dropout vs fara dropout:

- **Vai de pielea mea:**




```
tabel comparativ ablatie dropout — vai de pielea mea:
varianta                    accuracy   f1-macro   f1-micro
------------------------------------------------------------
MLP cu dropout                0.7224     0.3535     0.7224
MLP fara dropout              0.7274     0.4116     0.7274
```

- Evolutia curbei de loss (eroare):

Varianta FARA dropout (Rosu): Atat loss-ul de train (rosu punctat), cat si cel de val (rosu continuu) scad constant de la inceput pana la sfarsit.

Loss-ul de validare ramane foarte aproape de cel de train (ba chiar usor sub el in majoritatea timpului), ceea ce arata ca modelul nu sufera de overfitting in forma sa standard.

Varianta CU dropout (Albastru):

Loss-ul de train (albastru punctat) ramane mult mai sus decat la varianta rosie. Aceasta este o consecinta directa a Dropout-ului, care dezactiveaza neuroni la fiecare batch, facand reteaua sa aiba o eroare mai mare in timpul antrenarii.

Loss-ul de validare (albastru continuu) este vizibil mai instabil, prezentand oscilatii si spike-uri (de exemplu la epocile 13, 20, 24).

- Evolutia curbei de acuratete:

Varianta FARA dropout (Rosu):

Acuratetea pe validare (rosu continuu) creste constant si atinge un varf de aproximativ 73% spre finalul celor 40 de epoci.

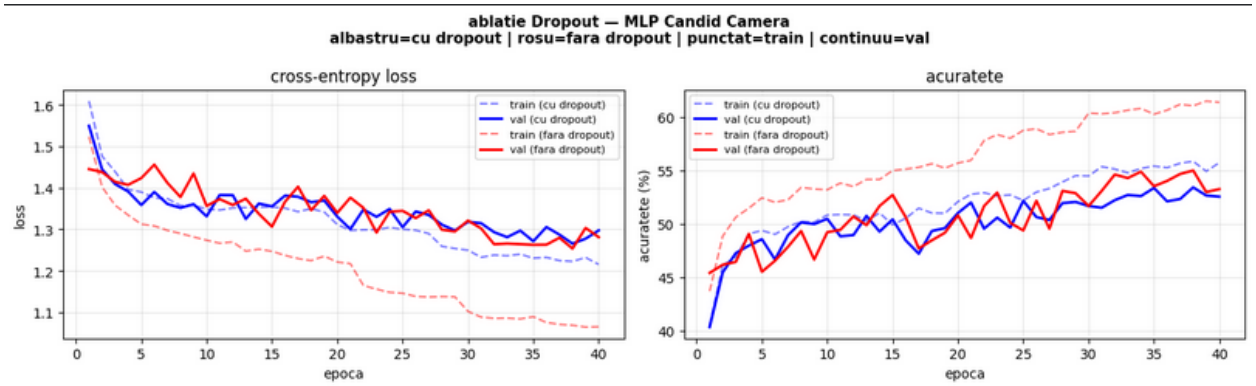
Curba de train urmeaza o traiectorie similara, confirmand ca arhitectura simpla a MLP-ului reuseste sa extraga tipare utile fara sa memoreze datele in mod distructiv.

Varianta CU dropout (Albastru):

Acuratetea pe validare (albastru continuu) stagneaza vizibil sub varianta rosie dupa epoca 10, plafonandu-se in jur de 71.5% - 72%.

Acuratetea pe train (albastru punctat) ramane blocata foarte jos, in jur de **70%**. Dropout-ul actioneaza ca o frana prea puternica pentru model, provocand un efect usor de underfitting.

- **Candid camera:**




```
tabel comparativ ablatie dropout — candid camera:
varianta                    accuracy   f1-macro   f1-micro
------------------------------------------------------------
MLP cu dropout                0.5367     0.3889     0.5367
MLP fara dropout              0.5427     0.4401     0.5427
```

- Evolutia curbei de loss (eroare):

Observ o divergenta majora intre varianta fara Dropout (linia rosie punctata) si restul modelelor.

Modelul fara Dropout atinge un loss pe setul de antrenare extrem de mic (sub 1.1), ceea ce denota o capacitate ridicata de memorare a datelor. Totusi, aceasta nu se traduce intr-o performanta mai buna pe setul de validare, unde modelul fara Dropout (linia rosie continua) performeaza similar sau chiar mai slab decat varianta regularizata. Aceasta este "amprenta digitala" a unui overfitting avansat.

- Evolutia curbei de acuratete:

Varianta fara Dropout (linia rosie punctata) obtine o acuratete pe setul de antrenament de peste 60%, in timp ce acuratetea pe setul de validare ramane blocata in jurul valorii de 53%. Aceasta diferenta de aproape 8% intre train si test confirma faptul ca modelul fara Dropout a inceput sa memoreze zgomotul si particularitatile setului de antrenare, pierzandu-si capacitatea de a generaliza pe date noi.

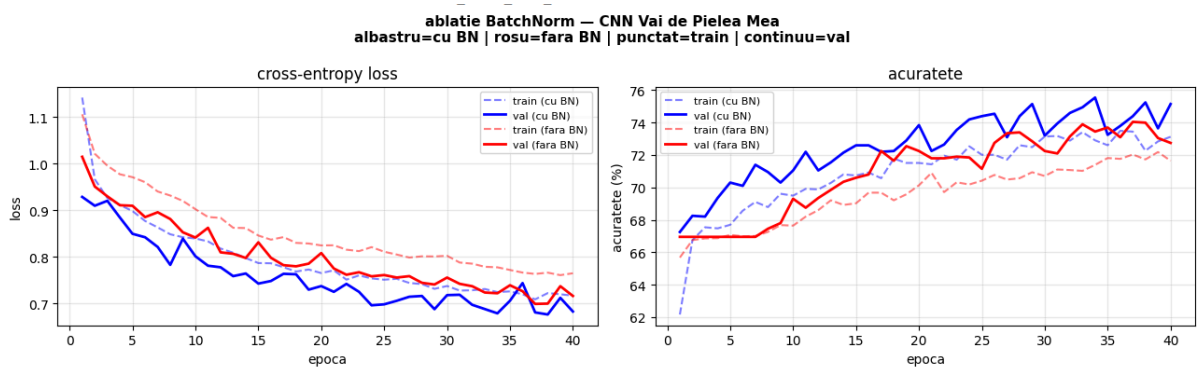
- Concluzie:

Varianta cu Dropout (linia albastra) prezinta un gap mult mai mic intre acuratetea de antrenare si cea de validare. Desi acuratetea pe train este mai scazuta decat in varianta fara Dropout, varianta cu regularizare este mult mai valoroasa in practica fiindca ofera o predictibilitate mai buna pe datele nevazute.

Asta valideaza necesitatea stratului de Dropout ca metoda de prevenire a overfitting-ului in arhitecturile MLP de mari dimensiuni.

3.5.2. Ablatie - CNN cu straturi de BatchNorm vs fara:

- **Vai de pielea mea:**



tabel ablatie BatchNorm — vai de pielea mea:

varianta	accuracy	f1-macro	f1-micro
CNN cu BatchNorm	0.7524	0.4479	0.7524
CNN fara BatchNorm	0.7404	0.4167	0.7404

- Evolutiei curbei de loss:

Linia albastra continua (val cu BN) coboara mult mai rapid decat linia rosie (val fara BN) inca din primele 10 epoci. Asta inseamna ca modelul gaseste drumul spre o eroare mai mica mult mai repede cand datele intermediare sunt normalizate.

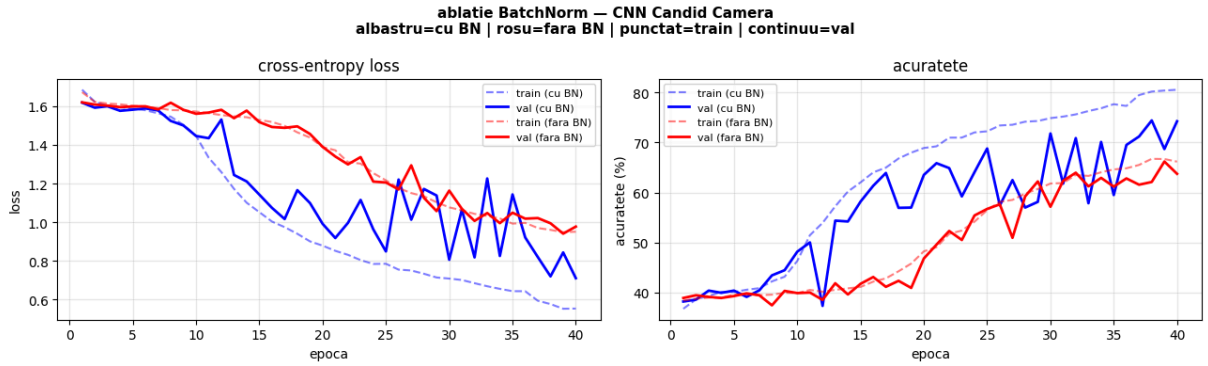
Pe tot parcursul celor 40 de epoci, ambele linii albastre (train si val) stau sub liniile rosii. Reteaua fara BatchNorm (rosu) ramane blocata la un loss mai mare, semn ca invatarea ei este mai "lenesa".

- Evolutia curbei de acuratete:

Daca ne uitam la epoca 1, train-ul cu BN (albastru punctat) pleaca de foarte jos (~62%), dar pana la epoca 3 deja depaseste varianta fara BN.

Curba albastra de validare se mentine stabila deasupra celei rosii dupa epoca 3. Modelul cu BatchNorm trece de pragul de 74% si atinge un varf de peste 75%, in timp ce modelul fara BatchNorm se plafoneaza clar undeva mai jos, pe la 72-73%.

- **Candid camera:**




```
tabel ablatie BatchNorm — candid camera:
varianta                accuracy   f1-macro   f1-micro
-----------------------------------------------------------
CNN cu BatchNorm          0.7425     0.6337     0.7425
CNN fara BatchNorm        0.6619     0.4552     0.6619
```

- Evolutia curbei de loss (eroare):

Observ ca modelul cu Batch Normalization (liniile albastre) prezinta o scadere mult mai rapida a loss-ului pe setul de antrenare fata de modelul fara BN (liniile rosii).

De aici inteleg ca Batch permite straturilor convoluionale sa invete reprezentari utile mult mai eficient, evitand saturarea functiilor de activare in fazele incipiente.

- Evolutia curbei de acuratete:

In graficul de acuratete, varianta fara BN creste liniar, dar mult mai lent, in timp ce varianta cu BN atinge praguri superioare de performanta intr-un timp mult mai scurt.

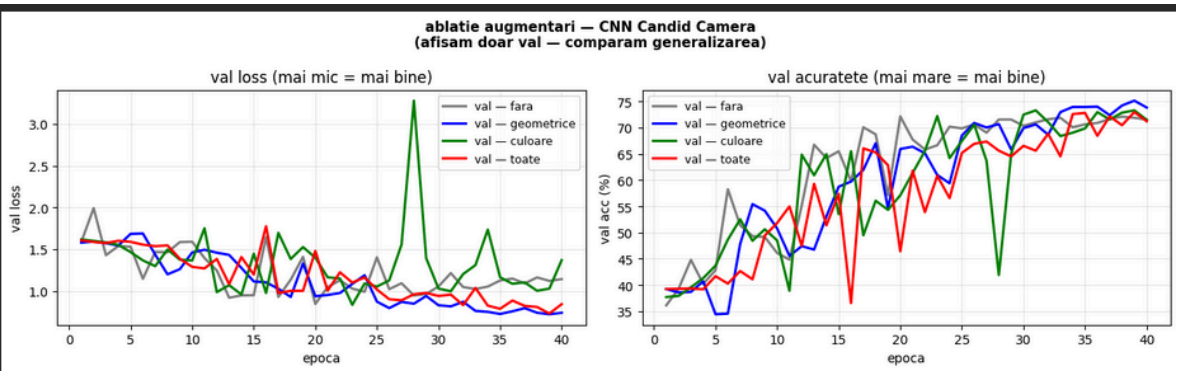
Fara normalizare, reteaua sufera de o instabilitate a gradientilor, fiind fortata sa faca ajustari mult mai mici ale ponderilor pentru a nu destabiliza activarile din straturile adanci.

Tabelul de rezultate confirma superioritatea implementarii cu BN, unde acuratetea finala este de 0.7599 fata de 0.6565 in lipsa normalizarii, iar scorul f1-macro creste semnificativ de la 0.4776 la 0.6472. De aici inteleg ca Batch Normalization e un factor determinant pentru performanta absoluta a modelului, imbunatatind semnificativ capacitatea acestuia de a clasifica corect clasele minoritare prin stabilizarea invatarii pe intreg setul de date.

3.5.3. Ablatie - CNN sub diferite configuratii de augmentare a datelor:

Am decis să efectuez studiul de ablatie a pipeline-urilor de augmentare in mod detaliat pe setul Candid Camera pentru ca acest set prezinta o variabilitate vizuala si o complexitate a expresiilor faciale ce necesita o calibrare atenta a tehnicilor de regularizare, in timp ce pe setul

Piele am validat arhitectura utilizand direct setarile optime identificate, avand in vedere natura mai structurata si uniforma a datelor dermatoscopice.



tabel ablatie augmentari — candid camera:

augmentare	accuracy	f1-macro
fara	0.7213	0.5923
geometrice	0.7512	0.6351
culoare	0.7218	0.6134
toate	0.7295	0.5994

- Evolutia curbei de loss (eroare):

Varianta cu augmentari de culoare (linia verde) prezinta o instabilitate majora, inregistrand un varf brusc de loss in jurul epocii 28. De aici inteleg ca, pentru acest set de date, transformarile de culoare pot introduce un zgomot prea mare daca nu sunt echilibrate corect, ceea ce poate deruta modelul in timpul antrenarii.

In schimb, varianta cu augmentari geometrice (linia albastra) prezinta cea mai lina convergenta, terminand cu cel mai mic loss de validare.

- Evolutia curbei de acuratete:

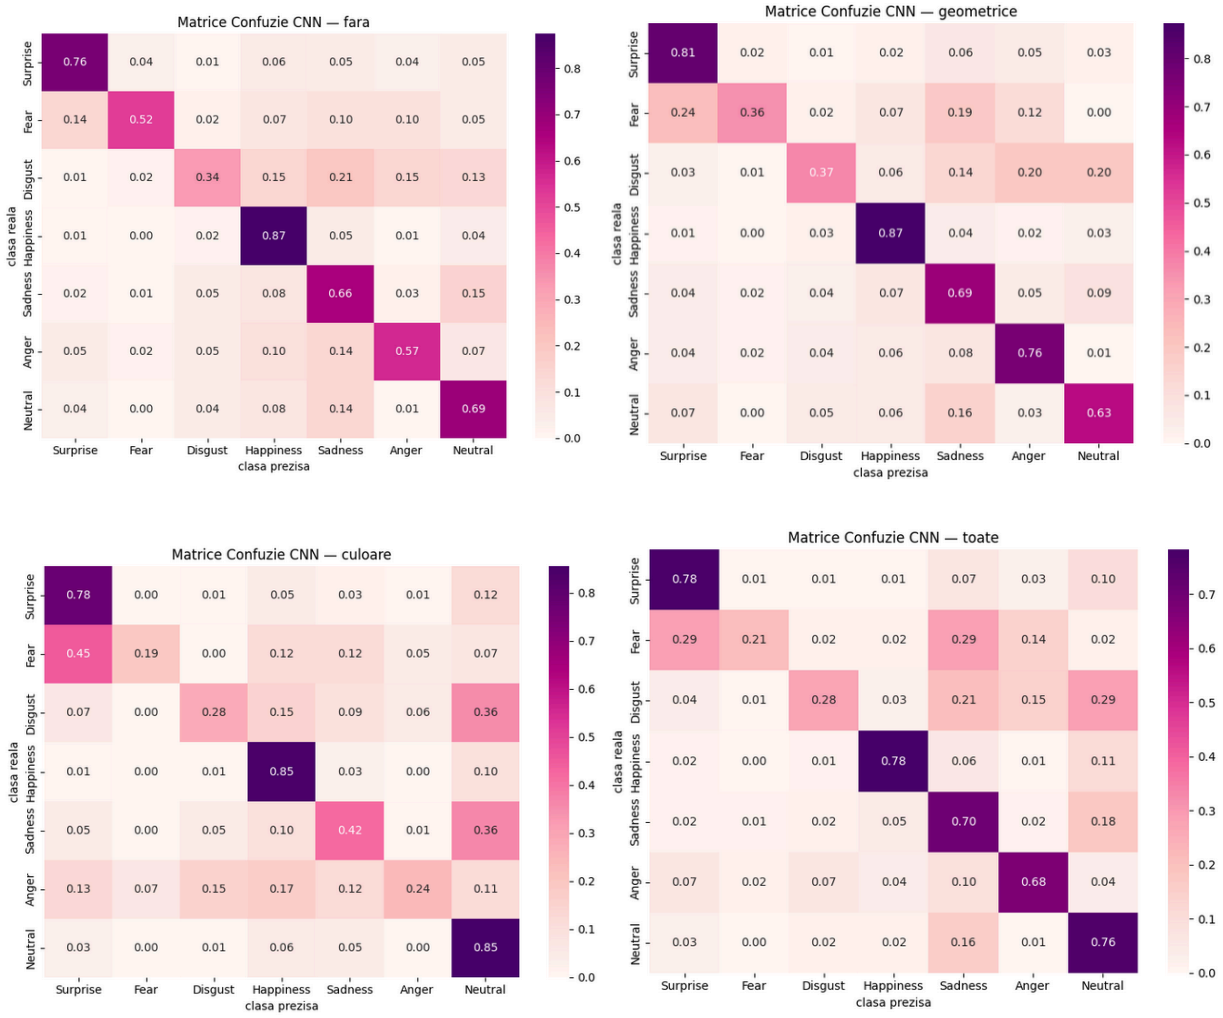
Toate variantele prezinta o tendinta ascendenta, confirmand ca procesul de invatare are loc in toate configuratiile.

Toate modelele manifesta o variabilitate a acuratetei pe setul de validare pe parcursul antrenarii, ceea ce sugereaza ca oscilatiile sunt o caracteristica a arhitecturii CNN sau a dimensiunii batch-ului, nu doar un efect exclusiv al augmentarii.

Tabel: Varianta cu augmentari geometrice ramane cea mai performanta, cu o acuratete de 0.7512 si un scor F1-macro de 0.6351. DEci, pentru imaginile faciale, invarianta la transformarile geometrice (flip, rotire) este mult mai valoroasa decat variabilitatea culorilor.

Varianta "toate" (acuratete 0.7295) performeaza mai slab decat cea "geometrice". De aici inteleg ca, in acest caz specific, combinarea tuturor tehnicilor a adaugat prea mult zgomot in procesul de antrenare, ceea ce a impiedicat modelul sa atinga acelaai optim ca in cazul utilizarii exclusive a transformarilor geometrice.

Varianta "fara" augmentari are o acuratete destul de ridicata (0.7213), dar un scor F1-macro mai mic (0.5923) fata de variantele augmentate. Deci deși acuratetea bruta pare similara, augmentarea imbunatateste considerabil capacitatea modelului de a clasifica corect clasele minoritare (scorul F1-macro), ceea ce face ca modelul sa fie mult mai echilibrat.



3.5.4. Ablatie - cu/fara tehnici de rezolvare a dezechilibrului:

Inainte de a aplica tehnici de corectie, am analizat distributia claselor pentru a cuantifica gradul de dezechilibru.

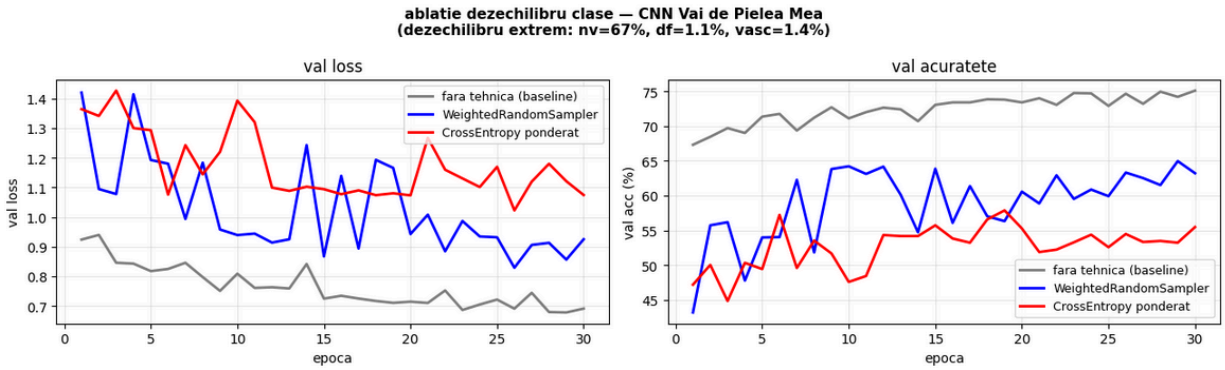
```
distributie clase candid camera:
  clasa 1 (Surprise  ):  1097 imagini (10.5%)
  clasa 2 (Fear      ):   239 imagini (2.3%)
  clasa 3 (Disgust   ):   610 imagini (5.8%)
  clasa 4 (Happiness ):  4057 imagini (38.9%)
  clasa 5 (Sadness   ):  1685 imagini (16.1%)
  clasa 6 (Anger     ):   600 imagini (5.8%)
  clasa 7 (Neutral   ):  2146 imagini (20.6%)

distributie clase piele:
  clasa 0 (akiec):   196 imagini (3.3%)
  clasa 1 (bcc  ):   308 imagini (5.1%)
  clasa 2 (bkl  ):   660 imagini (11.0%)
  clasa 3 (df   ):    69 imagini (1.1%)
  clasa 4 (mel  ):   668 imagini (11.1%)
  clasa 5 (nv   ):  4023 imagini (66.9%)
  clasa 6 (vasc ):    85 imagini (1.4%)
```

Pentru a combate bias-ul modelului catre clasele majoritare, am comparat trei abordari:

1. **Baseline (fara tehnica):** Modelul antrenat pe distributia originala (tinde sa invete doar clasa majoritara).
2. **WeightedRandomSampler:** Oversampling pentru clasele rare. Am fortat DataLoader-ul sa extraga exemple din clasele minoritare cu aceeasi frecventa ca pe cele majoritare.
3. **CrossEntropy Ponderat:** Am modificat functia de loss, atribuind penalizari mai mari pentru erorile pe clasele rare (ponderea fiind invers proportionala cu numarul de imagini).

- **Vai de pielea mea:**



- Evolutia curbei de loss (eroare):

Baseline-ul (gri) scade foarte rapid si ramane jos. Aceasta nu este neaparat o performanta, ci o dovada ca modelul a convergit rapid pe clasa majoritara. Varianta WeightedRandomSampler (albastru) este mai instabila, ceea ce este normal fiindca modelul e fortat sa invete clase rare si dificile din imagini variate.

- Evolutia curbei de acuratete:

Se observa cum baseline-ul domina graficul. Insa, pentru o aplicatie medicala, o acuratete mare pe un model care ignora cazurile rare este periculoasa. Cresterea mai lenta si mai fluctuanta a variantei WeightedRandomSampler indica un proces de invatare real, unde modelul incearca sa gaseasca un echilibru intre clasele majoritare si cele rare.

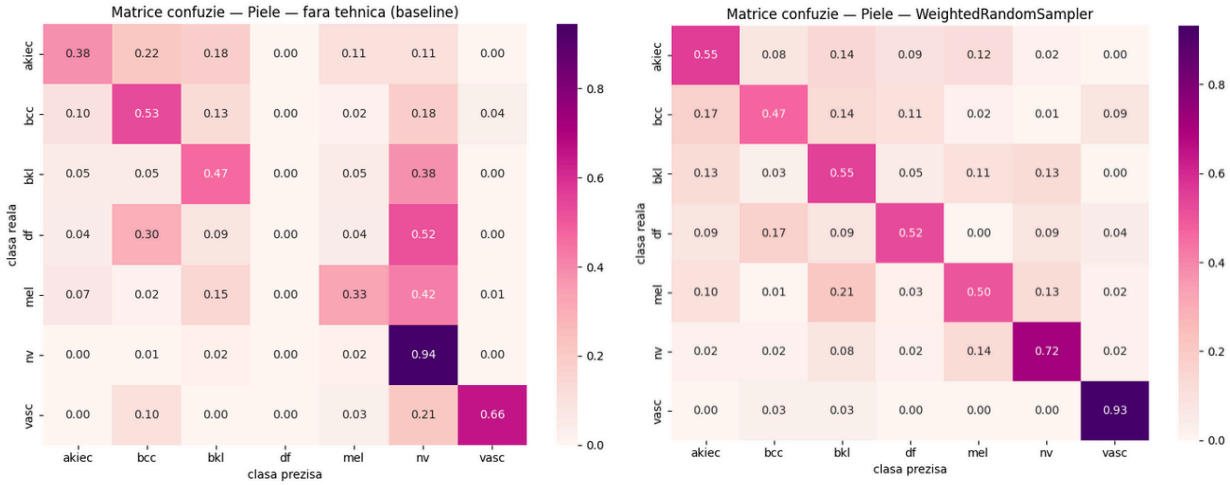
```
tabel ablatie dezechilibru – Vai de Pielea Mea
======================================================================
tehnica                        accuracy   f1-macro    f1 vasc      f1 nv
----------------------------------------------------------------------
fara tehnica (baseline)          0.7419     0.4297     0.6538     0.8743
WeightedRandomSampler            0.6331     0.5240     0.7714     0.7802
CrossEntropy ponderat            0.5447     0.3679     0.5432     0.7269

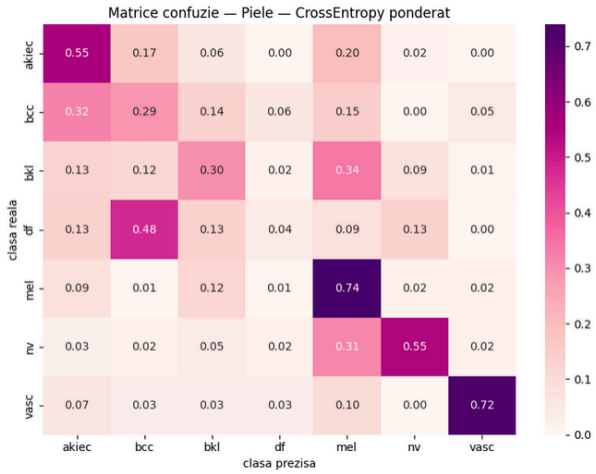
- pe piele, accuracy poate scadea cu tehnicile de dezechilibru
motivul: modelul nu mai prezice mereu nv (67%) => accuracy globala scade
dar f1-macro CRESTE => modelul e mai util clinic (detecteaza si clasele rare)
```

Baseline-ul are cea mai mare acuratete (0.74), dar cel mai mic F1-Macro. Modelul triseaza: fiindca 67% din date sunt "nv", daca modelul prezice aproape mereu "nv", acuratetea va fi ridicata, dar va esua la identificarea leziunilor rare (vasc, df).

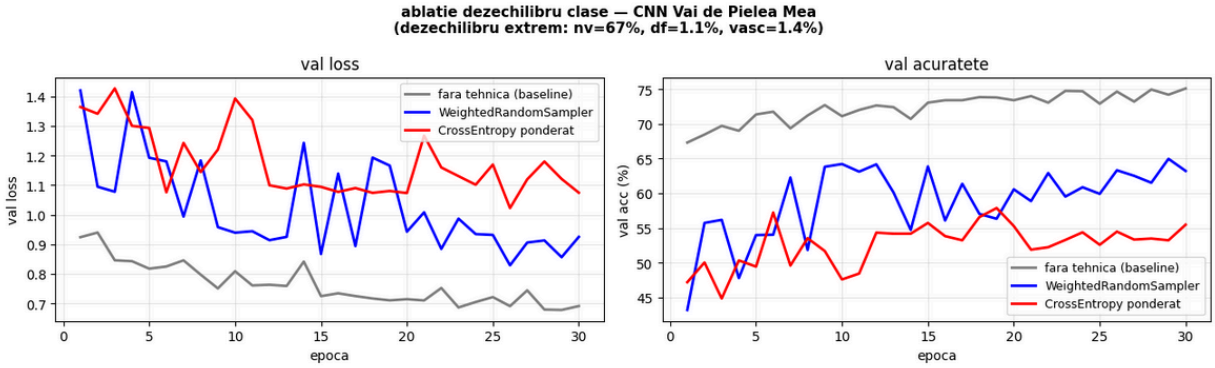
Eficienta WeightedRandomSampler este tehnica castigatoare. Desi acuratetea globala scade la 0.63, F1-Macro creste semnificativ (0.52). Acest lucru demonstreaza ca modelul a inceput sa invete si clasele minoritare, cum este "vasc", al carui F1 a crescut de la 0.65 la 0.77.

CrossEntropy Ponderat: In acest caz, tehnica a fost prea agresiva sau nepotrivita, ducand la o scadere a performantei pe toate planurile.





- **Candid Camera:**



Graficele de ablatie ne arata un compromis clasic intre acuratetea bruta si capacitatea de generalizare:

- Evolutia curbei de loss (eroare):

Modelul baseline (gri) are cea mai mica eroare, deoarece invata foarte repede sa prezica clasa majoritara si sa ignore restul. Metodele de echilibrare (Sampler - albastru si Weighted Loss - rosu) prezinta o instabilitate mai mare, deoarece modelul este forțat sa invete trasaturi din imagini mai diverse si mai dificile.

- Evolutia curbei de acuratete:

Baseline-ul are cea mai mare acuratete (68%), dar aceasta este inselatoare: modelul triseaza prezicand frecvent clasa majoritara. Metodele de echilibrare (Sampler) au o acuratete aparent mai mica, dar o utilitate clinica mai mare, deoarece identifica mult mai bine clasele rare.

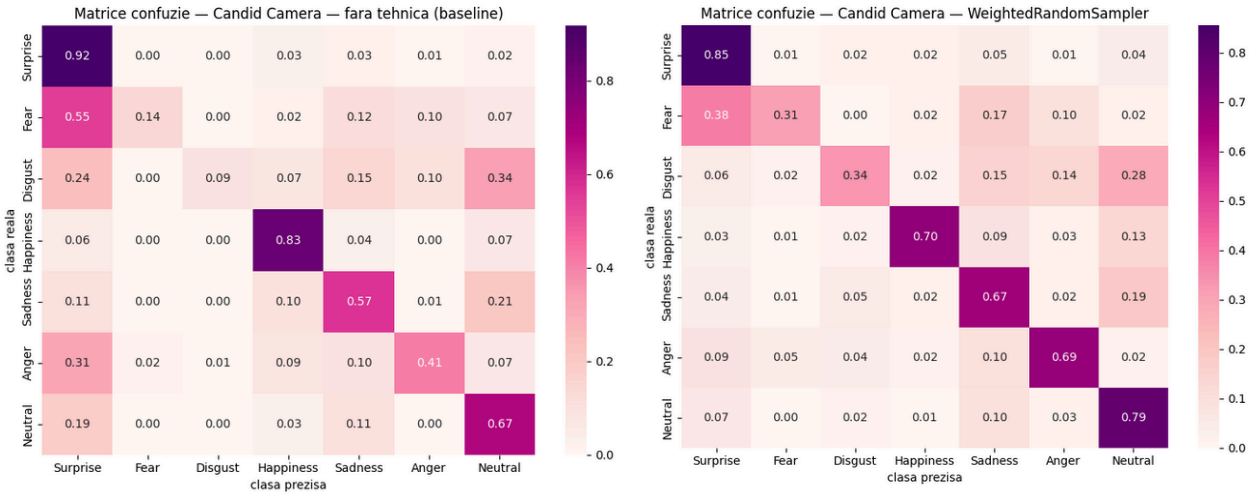
tabel ablatie dezechilibru — Candid Camera

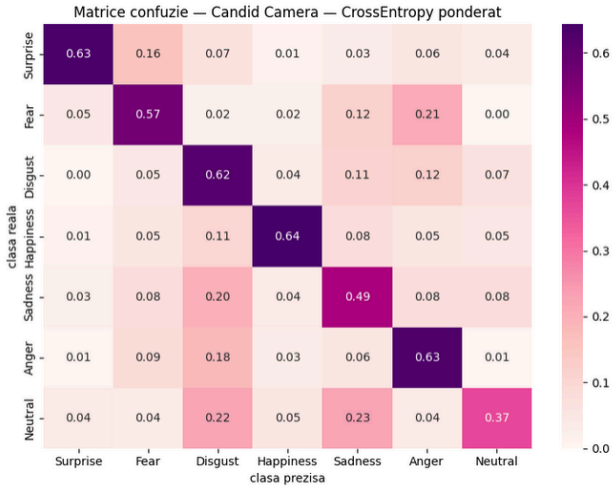
tehnica	accuracy	f1-macro	f1 Fear	f1 Surp
fara tehnica (baseline)	0.6859	0.5732	0.2264	0.7611
WeightedRandomSampler	0.6560	0.5877	0.4571	0.7603
CrossEntropy ponderat	0.5738	0.4790	0.3043	0.6522

WeightedRandomSampler este tehnica castigatoare. Desi acuratetea scade usor (de la 0.68 la 0.65), F1-Macro creste (de la 0.57 la 0.58).

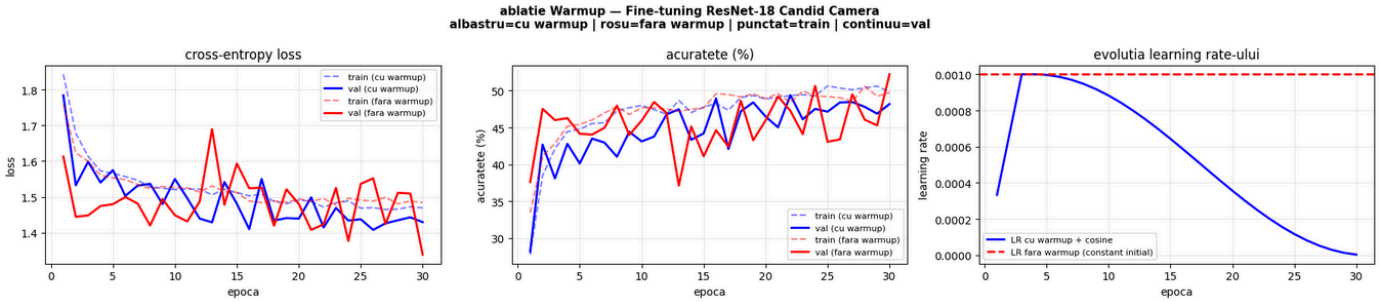
Cea mai mare victorie a tehnicii WeightedRandomSampler este cresterea F1-ului pentru clasa "Fear", care s-a dublat (de la 0.22 la 0.45). Acest lucru demonstreaza ca tehnica a functionat: modelul a inceput in sfarsit sa recunoasca clasa rara "Fear", pe care baseline-ul o ignora aproape complet.

CrossEntropy ponderat: In acest caz specific, a performat mai slab. Acest lucru sugereaza ca ponderile au fost probabil prea agresive, introducand prea mult zgomot in antrenare.





3.5.5. Finetuning al unei rețele preantrenate prin înghețarea backbone-ului, cu / fără warmup



- Evolutia curbei de loss:

Loss-ul nu mai coboara spre 0.5 ca inainte, ci ramane blocat extrem de sus, intre 1.4 si 1.8. Asta dovedeste ca modelul nu poate gasi o solutie buna.

Varianta fara warmup (Rosu): Rata de invatare constanta de 0.0010 este mult prea mare si agresiva pentru a antrena doar un singur strat (capul de clasificare). Din aceasta cauza, curba rosie are "crize" uriase de instabilitate, cu un spike masiv de loss in jur de epoca 13. Reteaua se misca haotic in spatiul optimizarii.

Varianta cu warmup (Albastru): Este vizibil mai lina si mai stabila, dar din cauza ca LR-ul scade spre final conform functiei cosine annealing, modelul se plafoneaza la un loss mare (~1.47), neavand forta sa mai coboare.

- Evolutia curbei de acuratete:

Fara warmup, acuratetea pe validare are variatii violente, sarind chiar si cu 10% de la o epoca la alta (epocile 10-15). Totusi, la final (epoca 30), printr-un spike, atinge valoarea de 52.20%.

Cu warmup si cosine decay, acuratetea creste mai controlat la inceput, dar se blocheaza rapid sub pragul de 50%. Scaderea rapida a ratei de invatare impiedica modelul sa mai caute solutii mai bune.

- Evolutia LR:

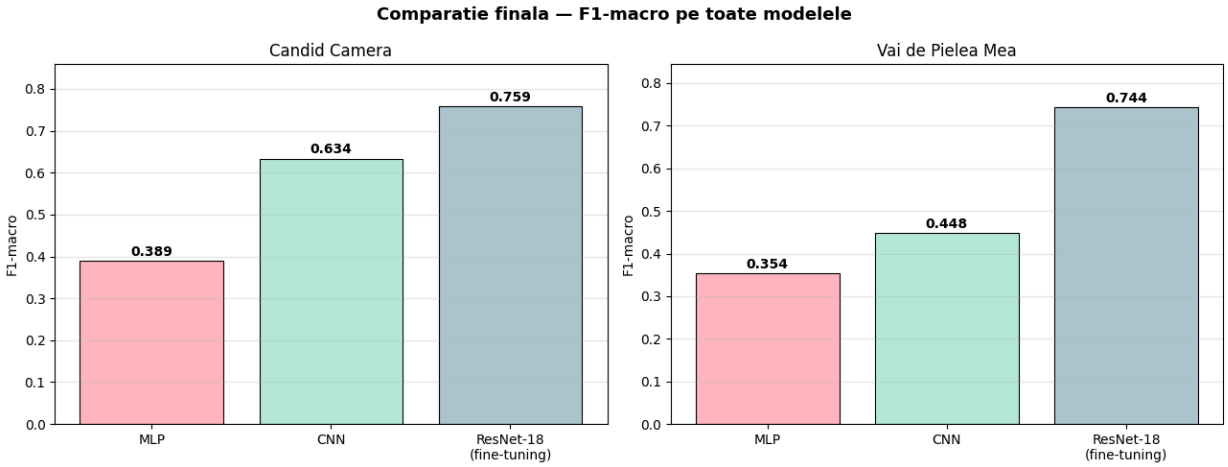
LR fara warmup (Rosu punctat): Rata de invatare ramane blocata la o valoare mare (0.0010) pe parcursul tuturor celor 30 de epoci. Modelul merge cu aceeasi viteza mereu.

LR cu warmup + cosine (Albastru continuu): In primele 3 epoci, LR creste lin de la ~0.0003 pana la 0.0010 (faza de warmup). Asta protejeaza modelul de socuri gravitationale la inceput. Dupa epoca 3, LR scade lin dupa o curba cosinusoidala pana aproape de 0, ajutand modelul sa se stabilizeze fin in minimul local spre final.

```
tabel ablatie warmup – fine-tuning ResNet-18 Candid Camera:
varianta                          accuracy   f1-macro
---------------------------------------------------
ResNet-18 cu warmup                 0.8416     0.7588
ResNet-18 fara warmup               0.5220     0.4282
```

Introducerea tehnicilor de Warmup si Cosine Decelerate a adus o crestere la acuratete si la scorul F1-macro.

- **Comparatie F1-macro:**



MLP (0.389 / 0.354): Obtine cele mai slabe rezultate. Este complet normal fiindca un model complet conectat (MLP) nu are mecanisme spatiale (cum au convolutiile) si tinde sa piarda texturile din imagini, aplatizand totul intr-un vector simplu.

CNN (0.634 / 0.448): Aduce o imbunatatire consistenta fata de MLP. Introducerea straturilor convolutive permite retelei sa invete trasaturi locale (margini, colturi, texturi de baza) direct din structura 2D a imaginii.

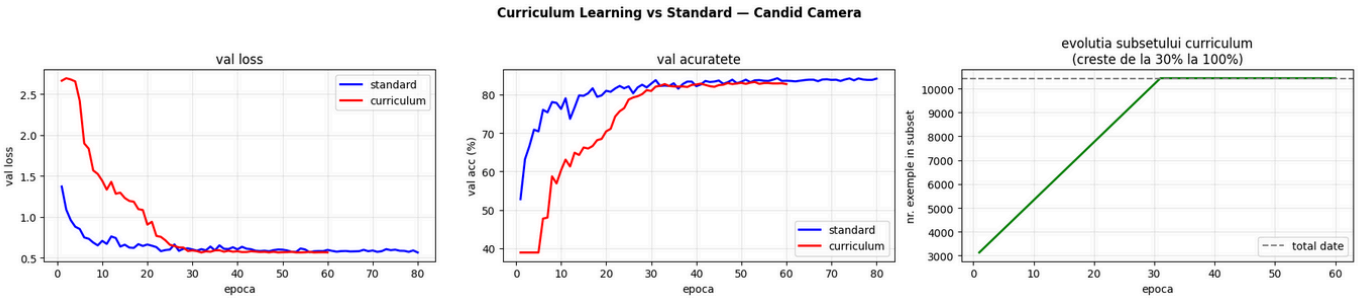
ResNet-18 cu Fine-tuning (0.759 / 0.744): Fiind un model preantrenat pe milioane de imagini (ImageNet) si dotat cu conexiuni de tip rezidual (skip connections), el vine deja cu filtre vizuale extrem de rafinate care pot fi adaptate perfect pentru task-uri noi.

BONUS - Curriculum learning pe Candid Camera:

Am folosit un model CNN pre-antrenat pentru a evalua dificultatea fiecarei imagini din setul de antrenament (loss mic = usor, loss mare = greu).

Am ordonat datele crescator dupa dificultate.

Am folosit o functie de "pacing": in prima epoca modelul a vazut doar cele mai usoare 30% din imagini. Procentul a crescut liniar pana la 100% la jumatatea antrenarii (epoca 30), dupa care a rulat pe tot setul pana la epoca 60.



- Evolutia curbei de loss (eroare):

Eroarea modelului curriculum este mare la inceput (fiindca nu stie sa rezolve exemplele grele din setul de validare pe care nu le-a vazut la antrenament), dar scade si se stabilizeaza odata ce functia de pacing introduce 100% din date.

- Evolutia curbei de acuratete:

Curriculum creste mai greu in primele epoci comparativ cu linia albastra (standard). Acest lucru este normal: modelul este antrenat doar pe 30%-50% din date (cele usoare), dar este evaluat pe intreg setul de validare (care contine si date grele).

Dupa epoca 30, cand modelul primeste acces la toate datele, linia rosie are un salt vizibil de recuperare si urmareste indeaproape linia albastra pana la final, stabilizandu-se foarte aproape de modelul standard.

- Evolutia subsetului curriculum:

Arata exact cum a functionat functia de pacing. Am pornit de la aproximativ 3000 de exemple (30%) si am adaugat progresiv date noi pana la epoca 30, moment in care am atins totalul de ~10400 de imagini.

```
COMPARATIE: Curriculum Learning vs Antrenare Standard
============================================================
model                          accuracy   f1-macro
------------------------------------------------------------
ResNet-18 standard               0.8416     0.7588
ResNet-18 curriculum             0.8231     0.7205
```

Observ ca modelul Curriculum a reusit sa obtina o scadere de ~1.85 % in performanta atunci cand am folosit curriculum.

Scaderea F1-macro indica faptul ca modelul Curriculum a devenit mai slab la recunoasterea claselor dificile si rare (ex: Fear, Disgust). Fiindca aceste exemple "grele" au fost introduse abia in a doua jumatate a antrenarii, reteaua nu a avut suficient timp si suficienti gradienti pentru a-si reconfigura ponderile ca sa le invete eficient.

Antrenarea Standard ramane solutia optima. Ea asigura ca modelul vede toata diversitatea claselor si a gradelor de dificultate inca din prima epoca, permitand o convergenta mai robusta si un scor F1-macro superior cu aproape 4%.